DeepSeek OCR

论文：《DeepSeek-OCR: Contexts Optical Compression》
模型仓库：deepseek-ai/DeepSeek-OCR
代码仓库：deepseek-ai/DeepSeek-OCR

LLM 处理长文本时计算量正比于序列长度平方，因此面临效率问题。**DeepSeek OCR 提出视觉模态可以作为文本信息的高效压缩媒介**，将文本的图片作为 MLLM 的输入，并且利用视觉编码器压缩视觉 token 长度，实现单张包含文本的图像能以更少 token 表达丰富信息，达到比数字文本更高的压缩比。关键技术：

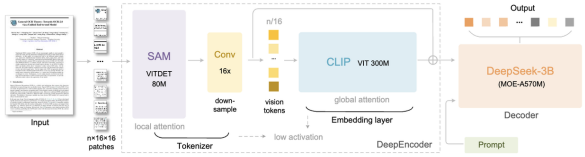
DeepEncoder 架构：串连了 SAM（local attention）+ Conv（压缩视觉序列长度）+ CLIP ViT（global attention）的视觉编码器，并且数据流宽度上，融合了 Local Feature 和 Global Feature 两路数据流

LLaVA-1.5(2023, Microsoft Research)模式的动态分辨率：不使用NaViT的 2D RopE 动态分辨率方案，而是使用一个全图 + 多个 Patch 特征在`seq_len`上进行拼接从而捕捉全局和局部信息。

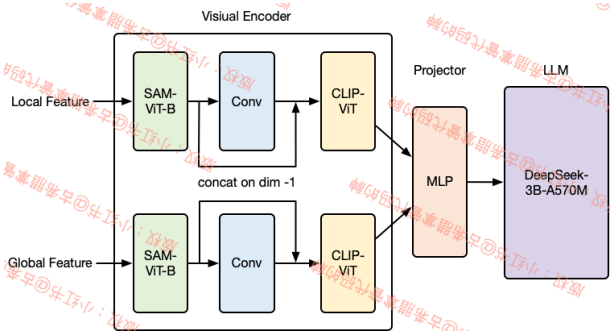
1. 模型架构

模型结构图参考下官方图（左），看起来似乎和现在的三段式 MLLM 的结构不一样，其实本质是一样的，可以参考（右）图，模型还是可以划分为 Visual Encoder、Projector、LLM 三个部分，**只不过架构上最大的更改其实只有视觉编码器Deep Encoder 部分**：

- 在结构深度上，串连了 SAM（local attention）+ Conv（压缩视觉序列长度）+ CLIP ViT（global attention）
- 在数据流宽度上，分别处理 Local Feature（Patch 内）和 Global Feature（Patch 间）



模型结构

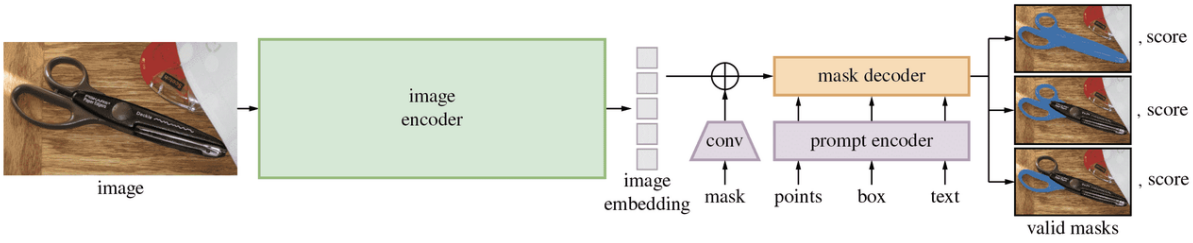


模型数据流

1.1 Deep Encoder

Deep Encoder 由 SAM（local attention）+ Conv（压缩视觉序列长度）+ CLIP ViT（global attention）组成。

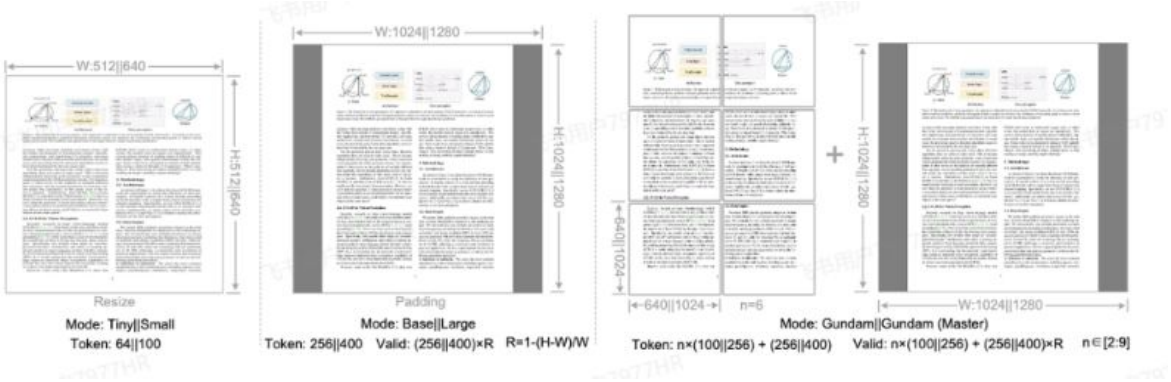
SAM 首先用于最先提取特征，架构和DeepSeek VL中是类似的，需要注意的点就是在代码实现的时候 Conv（压缩视觉序列长度）的结构也被写在了 SAM 里：



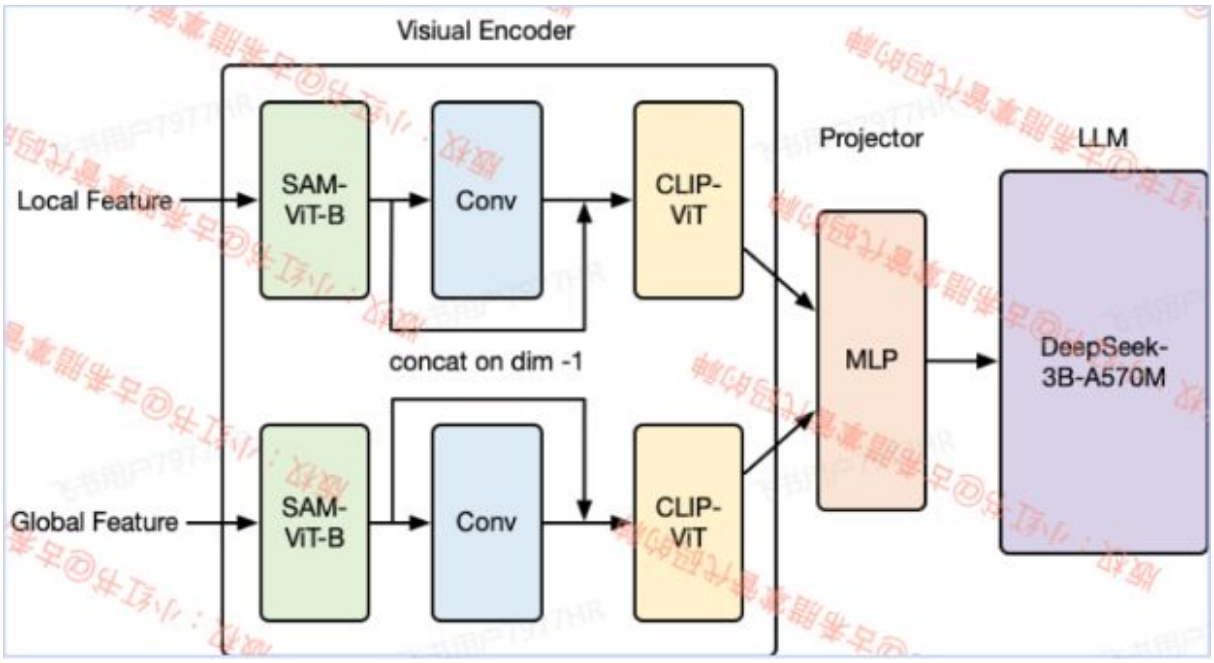
注意看在 SAM 结构里的 **net_2** 和 **net_3** 在 SAM 的输出侧就在`seq_len`完成了 4x4 = 16 倍的下采样，即压缩了视觉 token 长度：

然后在 Conv 后就是一个标准的 ViT 结构用于提取特征，但是需要注意两个点：

- DeepSeek OCR 分别对 Local Feature（Patch 内）和 Global Feature（Patch 间）进行特征提取，最后再 seq_len 上进行拼接，这点和LLaVA-1.5(2023, Microsoft Research)实现高分辨率的方案类似，也就是论文中支持动态分辨率的 Gundam 模型：



- 在 ViT 处理特征的时候，会同时处理 SAM 输出前后的特征，即类似一个 residual。



模型数据流

具体实现上参考代码：

1.2 Projector

Projector 的本质就是单层 Linear，这个和LLaVA(2023, Microsoft)是一样的，也可以参考MLLM 之 MLP Projector 发展史：

唯一的区别在于维度变化上，这是由于上一层结构`DeepEncoder V2`的维度决定的：

- OCR-V1 `2048 -> 1280`
- OCR-V2 `896 -> 1280`

1.3 LLM

采用 3B 参数的 MoE 架构（DeepSeek3B-MoE），推理时激活 6/64 个专家，实际激活参数约 570M。‘模型支持 8192 token 的超长序列处理，并且会进行文本数据（占总训练数据 10%）与多模态数据的混合训练。

2. 模型训练

两阶段训练，说起来**其实和其他通用 MLLM 比较类似，先对齐，再 Instruction Tuning。**

2.1 第一阶段：DeepEncoder 单独训练

这里首先是替换了 LLM 部分，替换为一个 Dense Model，然后冻结 LLM 部分，只训练 DeepEncoder。

损失函数依然采用 next token prediction，使用 OCR 1.0/2.0 数据和 100M LAION 数据集采样数据，

训练配置

- 2 个 epoch 训练周期
- 1280 批量大小
- AdamW 优化器
- 5e-5 初始学习率
- cosine annealing 学习率调度

2.2 第二阶段：DeepSeek-OCR 整体训练

使用混合数据（70% OCR 数据/20% 通用视觉数据/10% 纯文本数据）进行分布式训练，猜测应该是全参数进行训练。

多分辨率拓展通过动态位置编码插值实现多模式联合训练：

- 原生分辨率模式：512×512(64 tokens)/640×640(100 tokens)/1024×1024(256 tokens)/1280×1280(400 tokens)
- Gundam 动态模式：局部 640×640 切片 + 全局 1024×1024 视图，支持超高清输入

架构配置

- 流水线并行（PP）分 4 段：PP0/PP1 为 DeepEncoder（冻结 SAM-compressor 参数，训练 CLIP），PP2/PP3 为 MoE 解码器
- 3B MoE 解码器激活 570M 参数，专家路由选择 6/64 激活专家 +2 共享专家

训练参数

- 20 节点 8xA100-40G 集群
- 40 数据并行度，640 全局批量
- AdamW 优化器，3e-5 初始学习率
- 文本数据训练速度 90B tokens/天，多模态数据 70B tokens/天

3. 实验

可以看出小红书的dots.ocr还是不错的，实测的效果也比 DeepSeek OCR 要好。

Model	Tokens	English					Chinese				
		overall	text	formula	table	order	overall	text	formula	table	order
Pipline Models											
Dolphin [11]	-	0.356	0.352	0.465	0.258	0.35	0.44	0.44	0.604	0.367	0.351
Marker [1]	-	0.296	0.085	0.374	0.609	0.116	0.497	0.293	0.688	0.678	0.329
Mathpix [2]	-	0.191	0.105	0.306	0.243	0.108	0.364	0.381	0.454	0.32	0.30
MinerU-2.1.1 [34]	-	0.162	0.072	0.313	0.166	0.097	0.244	0.111	0.581	0.15	0.136
MonkeyOCR-1.2B [18]	-	0.154	0.062	0.295	0.164	0.094	0.263	0.179	0.464	0.168	0.243
PPstructure-v3 [9]	-	0.152	0.073	0.295	0.162	0.077	0.223	0.136	0.535	0.111	0.11
End-to-end Models											
Nougat [6]	2352	0.452	0.365	0.488	0.572	0.382	0.973	0.998	0.941	1.00	0.954
SmolDocling [25]	392	0.493	0.262	0.753	0.729	0.227	0.816	0.838	0.997	0.907	0.522
InternVL2-76B [8]	6790	0.44	0.353	0.543	0.547	0.317	0.443	0.29	0.701	0.555	0.228
Qwen2.5-VL-7B [5]	3949	0.316	0.151	0.376	0.598	0.138	0.399	0.243	0.5	0.627	0.226
OLMOCR [28]	3949	0.326	0.097	0.455	0.608	0.145	0.469	0.293	0.655	0.652	0.277
GOT-OCR2.0 [38]	256	0.287	0.189	0.360	0.459	0.141	0.411	0.315	0.528	0.52	0.28
OCRFlux-3B [3]	3949	0.238	0.112	0.447	0.269	0.126	0.349	0.256	0.716	0.162	0.263
GPT4o [26]	-	0.233	0.144	0.425	0.234	0.128	0.399	0.409	0.606	0.329	0.251
InternVL3-78B [42]	6790	0.218	0.117	0.38	0.279	0.095	0.296	0.21	0.533	0.282	0.161
Qwen2.5-VL-72B [5]	3949	0.214	0.092	0.315	0.341	0.106	0.261	0.18	0.434	0.262	0.168
dots.ocr [30]	3949	0.182	0.137	0.320	0.166	0.182	0.261	0.229	0.468	0.160	0.261
Gemini2.5-Pro [4]	-	0.148	0.055	0.356	0.13	0.049	0.212	0.168	0.439	0.119	0.121
MinerU2.0 [34]	6790	0.133	0.045	0.273	0.15	0.066	0.238	0.115	0.506	0.209	0.122
dots.ocr$^{\dagger 200dpi}$ [30]	5545	0.125	**0.032**	0.329	**0.099**	**0.04**	0.16	**0.066**	0.416	0.092	**0.067**
DeepSeek-OCR (end2end)											
Tiny	**64**	0.386	0.373	0.469	0.422	0.283	0.361	0.307	0.635	0.266	0.236
Small	100	0.221	0.142	0.373	0.242	0.125	0.284	0.24	0.53	0.159	0.205
Base	256(182)	0.137	0.054	0.267	0.163	0.064	0.24	0.205	0.474	0.1	0.181
Large	400(285)	0.138	0.054	0.277	0.152	0.067	0.208	0.143	0.461	0.104	0.123
Gundam	795	0.127	0.043	0.269	0.134	0.062	0.181	0.097	0.432	0.089	0.103
Gundam-M$^{\dagger 200dpi}$	1853	**0.123**	0.049	**0.242**	0.147	0.056	**0.157**	0.087	**0.377**	**0.08**	0.085