Qwen-VL

来源：飞书原文；2025 年 9 月 27 日修改

1. 模型架构

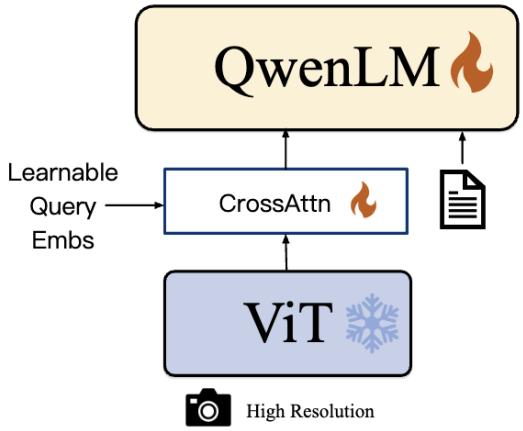


Table 1: Details of Qwen-VL model parameters.

Vision Encoder	VL Adapter	LLM	Total
1.9B	0.08B	7.7B	9.6B

1.1 ViT

视觉编码器的架构和预训练权重来自于 Openclip 的 ViT-bigG 模型。ViT-bigG/14 训练使用 LAION-2B（采样自LAION-5B的英文标注图文 pair 数据，框架是OpenCLIP。

在训练和推理过程中，将输入图像调整到特定的分辨率，然后通过将图像分割成大小为 14 的图块来处理它们，生成图像特征。

1.2 Position-aware Vision-Language Adapter

1）为了缓解由于长图像特征序列而产生的效率问题，Qwen-VL 引入了一个视觉-语言适配器，用于压缩图像特征。适配器包括一个随机初始化的单层交叉注意力模块（single-layer cross-attention module initialized randomly）。此模块使用一组可训练的向量（嵌入）作为 query，使用来自视觉编码器的图像特征作为交叉注意力操作的 keys、values。这个机制将视觉特征序列压缩到固定长度的 256。

注意，这个模块和mPLUG-OWL(2023, Alibaba)的区别在于这里并没有把 Q 拼接在 KV 上

2）**为了缓解 1D 位置编码对图片空间位置造成的损失，使用 2D 绝对位置编码。**

这里是有 2 个位置编码：

- VIT 有自己的可以学习的 1d-PE
- Resample 有自己的不可以学习的 2d-PE

1.3 LLM

Qwen-VL 的大型语言模型使用了来自 Qwen-7B 模型的**预训练**权重。

2. 训练

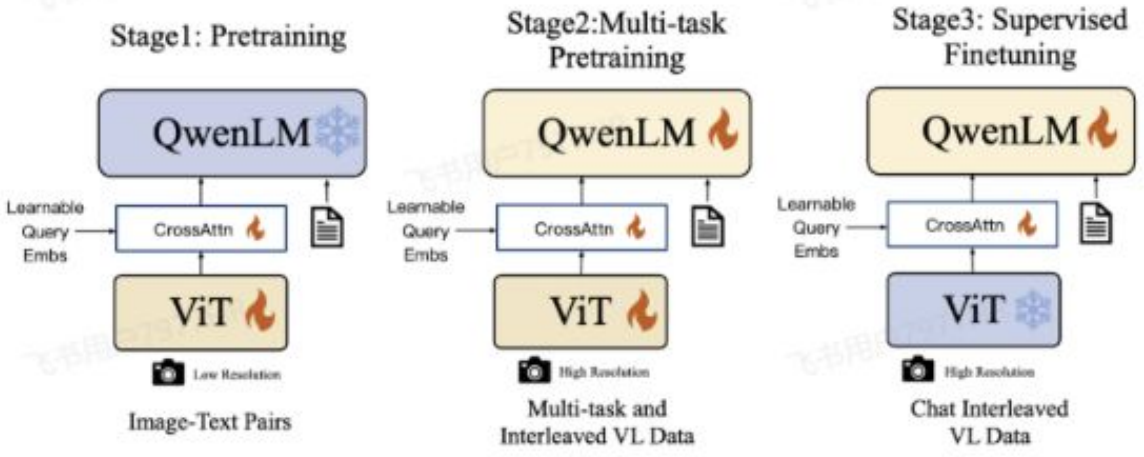


Figure 3: The training pipeline of the Qwen-VL series.

三阶段训练：

- Stage1 为预训练，目标是使用大量的图文 Pair 对数据对齐视觉模块和 LLM 的特征，这个阶段冻结 LLM 模块的参数；
- Stage2 为多任务预训练，使用更高质量的图文多任务数据（主要来源于开源 VL 任务，部分自建数据集），更高的图片像素输入，全参数训练；
- Stage3 为指令微调阶段，这个阶段冻结视觉 Encoder 模块，使用的数据主要来自大模型 Self-Instruction 方式自动生成，目标是提升模型的指令遵循和多轮对话能力。

2.1 Stage 1

损失函数仍然是针对文本标记的训练目标是最小化文本标记的交叉熵（cross-entropy）。

- 超参数设置

1）AdamW 优化器，并设置了以下超参数：$\beta_1 = 0.9$、$\beta_2 = 0.98$、$\varepsilon = 1e{-}6$

2）余弦学习率调度（cosine learning rate schedule）。最大学习率（maximum learning rate）为 2e−4，最小学习率（minimum learning rate）为 1e−6，线性热身（linear warm-up）步数为 500 步。

3）使用了权重衰减（weight decay）为 5e−2 和梯度剪切（gradient clipping）为 1.0 来优化模型的训练过程。

4）训练为 5w 步。

- 数据来源

Table 2: Details of Qwen-VL pre-training data. LAION-en and LAION-zh are the English and Chinese language subset of LAION-5B (Schuhmann et al., 2022a). LAION-COCO (Schuhmann et al., 2022b) is a synthetic dataset generated from LAION-en. DataComp (Gadre et al., 2023) and Coyo (Byeon et al., 2022) are collections of image-text pairs. CC12M (Changpinyo et al., 2021), CC3M (Sharma et al., 2018), SBU (Ordonez et al., 2011) and COCO Caption (Chen et al., 2015) are academic caption datasets.

Language	Dataset	Original	Cleaned	Remaining%
English	LAION-en	2B	280M	14%
	LAION-COCO	600M	300M	50%
	DataComp	1.4B	300M	21%
	Coyo	700M	200M	28%
	CC12M	12M	8M	66%
	CC3M	3M	3M	100%
	SBU	1M	0.8M	80%
	COCO Caption	0.6M	0.6M	100%
Chinese	LAION-zh	108M	105M	97%
	In-house Data	220M	220M	100%
	Total	5B	1.4B	28%

Qwen-VL 模型的第一个预训练阶段使用了一个大规模、弱标记的、通过网络爬取得到的图像文本对数据集。原始数据集中包含了 50 亿对图像文本对，而剩余的数据经过处理后仍然有 14 亿对，其中77.3% 为英文文本，22.7% 为中文文本。

总计 14 亿对样本，5000 亿的图像文本 tokens。

2.2 Stage 2

Qwen-VL 模型采用了高质量和细粒度的视觉-语言（VL）标注数据

采用了更大的输入分辨率和交错的图像-文本数据。

具体来说，Qwen-VL 模型在第二个预训练阶段同时进行了以下七个任务的训练：

- 图像描述（Captioning）
- 视觉问答（VQA）
- 定位任务（Grounding）
- 参考定位和定位描述的双重任务（Ref Grounding 和 Grounded Cap.）
- 光学字符识别（OCR）
- 文本生成（Text Generation）

在这个阶段，作者综合利用了不同的数据源和任务，使得模型能够在多方面进行训练，从而提升其对于图像与文本的综合理解能力。

2.3 Stage 3

在监督微调阶段，Qwen-VL 模型通过引入额外的指导微调数据来提升其交互和对话能力，从而生成了交互式的 Qwen-VL-Chat 模型。这些多模态的指导调整数据主要来自于图像描述或对话数据，这些数据可以通过 LLM self-instruction 生成。然而，这些数据通常只涵盖了单一图像对话和推理，且仅限于对图像内容的理解。因此，作者们通过手动标注、模型生成和策略串联等方法构建了一组额外的对话数据，以将定位和多图像理解能力融入到 Qwen-VL 模型中。

这样做的目的是确保模型可以有效地将这些能力传递到更广泛的语言和问题类型中，从而提升了模型在交互和对话方面的性能。在这个阶段，作者们将模型的视觉编码器冻结，仅优化语言模型和适配器模块，以保证模型的训练稳定和有效。

训练 Qwen-VL-Chat 模型的微调参数设定：

- 全局批次大小为 128 的训练方式
- 使用了具有最大学习率 1e-5、最小学习率 1e-6 和线性预热 3000 步的学习率调度。

微调模版：

The Dataset Format Example of ChatML

```
<im_start>user
Picture 1: <img>vg/VG_100K_2/649.jpg</img>What is the sign in the picture?<im_end>
<im_start>assistant
The sign is a road closure with an orange rhombus.<im_end>
<im_start>user
How is the weather in the picture?<im_end>
<im_start>assistant
The shape of the road closure sign is an orange rhombus.<im_end>
```