Qwen3-VL

> 来源：飞书在线文档；复刻日期：2026 年 10 月 30 日。按要求省略原文代码块。

论文：《Qwen3-VL Technical Report》
代码仓库：QwenLM/Qwen3-VL | 完整 PR 代码：代码链接 | 模型仓库：Qwen/qwen3-vl

25 年 9 月我们在Qwen3 VL Preview中超前解析了 Qwen3-VL 的模型架构，当时依靠模型代码以及 官方 Blog 无法对模型训练细节进行解析（并且当时没有开源全系列模型）。现在随着 Qwen3-VL 技术报告发布/模型完整开源，我们**重新来解析 Qwen3-VL 系列模型的关键技术！**

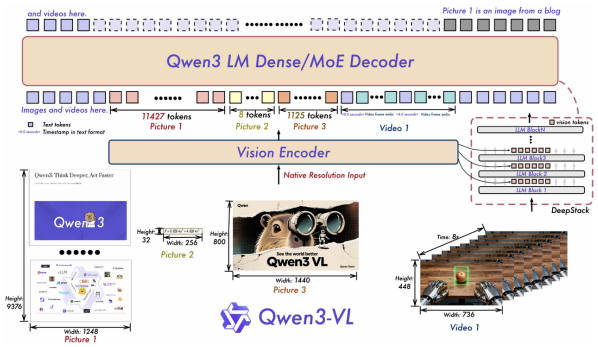
Qwen3-VL 是 Qwen 系列目前最先进的视觉-语言多模态模型（截止 2025 年 11 月），核心特性与创新：

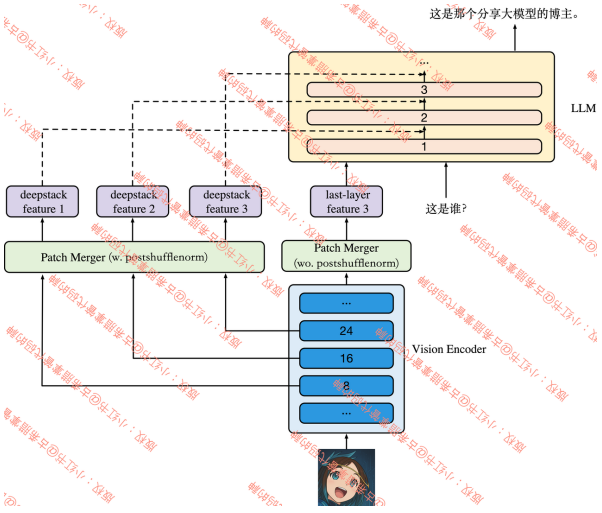
1. **架构主要改进（对比Qwen2.5-VL）**：使用的 DeepStack 的 Projector 整合多层级 ViT 特征提升视觉-语言对齐效果，LLM 支持 MoE 和 Dense 不同架构。替换MRoPE为 interleaved-MRoPE，强化图像/视频的时空特征建模的稳定性。
2. **长上下文支持**：原生支持 256K tokens 的长上下文，可无缝处理交错式文本、图像及视频输入。
3. **增强的后训练**：在多个细分领域进行 RL，采用 Qwen 团队的 SAPO，参考“think with images”多模态 agent 训练。

1. 模型架构

模型还是标准的“三段式结构”，即 **ViT+Projector+LLM**：

- **Vision Encoder**：SigLIP2架构，初始化于 SigLIP2-SO-400M、SigLIP2-Large (300M)，进行动态分辨率 CPT。沿用 Qwen2.5 bias 配置、2D-RoPE，但是替换了激活函数，PatchEmbed 启用 bias。
- **Projector**：Adaptor 本次更新中使用了两个部分特征，一部分是沿用的 Qwen2.5 的 PatchMerger（对比解析参考MLLM 之 MLP Projector 发展史）另外一部分使用了 `deepstack_visual_indexes`，**用于与 LLM 跨层进行特征融合。**
- **LLM**：Qwen3-VL-235B-A22B /Qwen3-VL-30B-A3B 使用的是Qwen 3的 MoE 版本，32B/8B/4B/2B 使用的是 Qwen3 的 Dense 版本，架构上使用了 QKNorm（解析参考QK Norm 的前世今生），与Qwen2.5-VL区别在于：Qwen3VL 改进了MRoPE为 Interleaved MRoPE。**并且在前 K 层使用了 DeepStack 特征融合。**





1.1 Vision Encoder

Vision Encoder 使用的SigLIP2架构，ViT 权重来自于 SigLIP2-SO-400M 和 SigLIP2-Large (300M)，后者用于 **2B/4B** 的轻量级模型。Qwen3-VL 对 ViT 增加 2D-RoPE后进行了动态分辨率的继续预训练，方法参考CoMP。对比Qwen2.5-VL在 ViT 上的区别：

- PatchEmbed

Qwen3-VL: Qwen3VLVisionPatchEmbed 使用 Conv3d，bias=True，默认 patch_size=16。

Qwen2.5-VL: Qwen2_5_VisionPatchEmbed 也用 Conv3d，bias=False，默认 patch_size=14。

- 位置编码：

两者都使用 2D-RoPE，即支持动态分辨率（参考NaViT）。

- MLP：

之前在Qwen2.5-VL中讲过，Qwen2.5-VL的 ViT-MLP 做出了更像语言模型架构的策略：

- 使用 SwiGLU 的 FFN 结构，`hidden_act="silu"`（参考1.1.5 前馈网络 FFN 和激活函数 Activation）
- 标准化使用 RMSNorm。
- 其中的线性层增加 bias，注意这里在 llama 这样的语言模型中是默认无偏置。

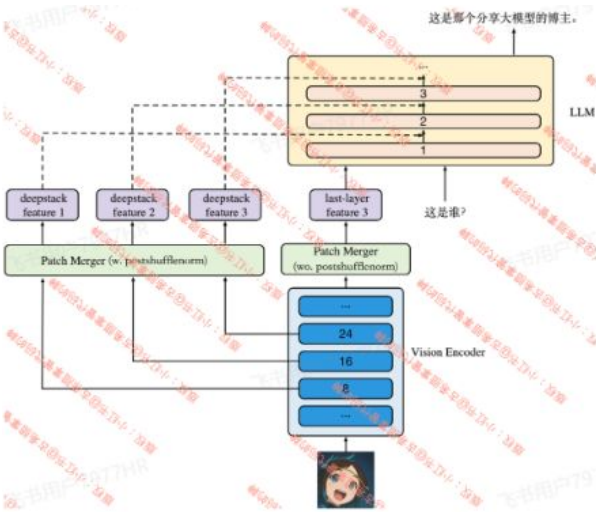
Qwen3VL 沿用了这一配置，除了激活函数：

但是细节变化在于激活函数由`silu`替换为了`gelu_pytorch_tanh`，参考代码：

1.1 Adaptor

Adaptor 在沿用了Qwen2.5-VL的基础上，增加了从 ViT 中间层到 LLM 前 k 层到特征融合通路。总的来讲，Qwen3-VL 的 Adaptor 包括两个部分：

- 一部分是沿用的 Qwen2.5 的 PatchMerger（对比解析参考MLLM 之 MLP Projector 发展史）
- 另外一部分使用了**`deepstack_visual_indexes`，用于与 LLM 特征进行融合。**如右图所示，通过特征通路进行视觉和语言的深度融合。



实现方式参考以下代码**蓝色**和**红色**部分：

可以看到，**deepstack_merger_list 分别针对 ViT 的第 [8, 16, 24] 层设置了 Qwen3VLVisionPatchMerger。**

但是这部分的关键参数设置在**use_postshuffle_norm**上区别于 PatchMerger，两者的关键区别在于先做 shuffle (这里的 shuffle 本质上是 hidden_dim 上进行 2*2 的堆叠，参考Qwen2.5-VL）还是先做 LayerNorm：

然后整体上看，Qwen3VLVisionModel（即 ViT 部分），提供给 LLM 的是两部分特征：

- hidden_states：最后一层通过 PatchMerger 的特征。
- **deepstack_feature_lists：第 [8, 16, 24] 层中间特征。**

代码参考，具体这两部分特征怎么用，我们看 LLM 部分代码：

至于为什么要用中间特征，参考：多模态 LLM 中 adapter 部分的设计，ViT 的特征取哪层哪个位置？(字节-2面)

1.2 LLM

分为Qwen 3的 MoE 版本/非 MoE 版本，具体开源的模型版本和 LLM 架构见表：

规格（架构）	模型名字
235B (MoE)	Qwen3-VL-235B-A22B-Instruct / Thinking / FP8 / GGUF
30B (MoE)	Qwen3-VL-30B-A3B-Instruct / Thinking / FP8 / GGUF
32B (Dense)	Qwen3-VL-32B-Instruct / Thinking / FP8 / GGUF
8B (Dense)	Qwen3-VL-8B-Instruct / Thinking / FP8 / GGUF
4B (Dense)	Qwen3-VL-4B-Instruct / Thinking / FP8 / GGUF
2B (Dense)	Qwen3-VL-2B-Instruct / Thinking / FP8 / GGUF

架构上使用了 QKNorm（解析参考QK Norm 的前世今生），对于非 MoE 版本进行分析，区别在于：

- Qwen3VL 使用 3 维多模态位置编码 MRoPE，Qwen3 则使用标准 RoPE。
- Qwen3 支持 sliding window 层，Qwen3VL 未引入。
- **在前 K 层使用了 DeepStack 特征融合。（详细参考 Qwen3-VL 的 DeepStack 技术是什么？）**

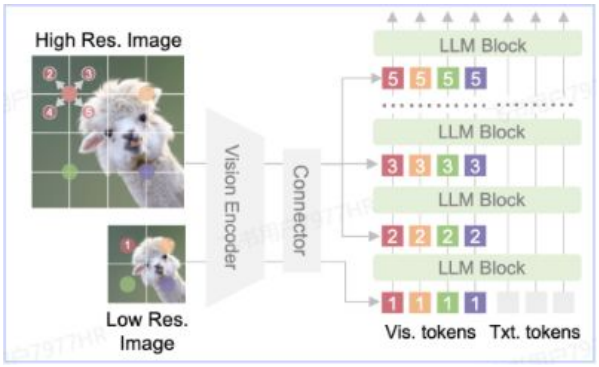
我们具体来看，ViT 输出的特征如何与 LLM 特征进行融合的，首先 ViT 输出的特征是两部分：

- hidden_states：最后一层通过 PatchMerger 的特征。
- **deepstack_feature_lists：第 [8, 16, 24] 层中间特征。**

首先对于 hidden_states，直接与文本特征拼接输入 LLM：

然后对于**deepstack_feature_lists，则是分别与前 K 层（这里是前三层，`K=len(deepstack_feature_lists)`）进行融合。**

我们首先来看这部分融合的代码逻辑：



然后融合的方式参考 _deepstack_process 函数，具体处理逻辑为：

- 把 hidden_states 在 visual_pos_masks 为 True 的位置切出来，加上对应层的视觉特征向量 visual_embeds（就是 deepstack_visual_embeds[layer_idx]，它已经对齐到“**只有视觉位置**”的子序列顺序）。
- 再写回到 hidden_states 的这些视觉位置。

这等价于：在若干前层（deepstack 的层数）里，用视觉中间层特征对语言隐藏态进行残差式强制注入，**仅作用于视觉 token 的那些位置，文本 token 位置不变：**

1.2.1 Interleaved MRoPE

鹅圈子有详细解析，麻烦查看：链接

2. 预训练

2.1 训练配置

Stage	Objective	Training	Token Budget	Sequence Length
S0	Vision-Language Alignment	Merger	67B	8,192
S1	Multimodal Pre-Training	All	~1T	8,192
S2	Long-Context Pre-Training	All	~1T	32,768
S3	Ultra-Long-Context Adaptation	All	100B	262,144

首先在 S0 之前需要对 ViT 进行 CPT（继续预训练），主要目标是拓展其在动态分辨率下的能力，这部分不算在 Stage 里面。

1. **Stage-0：视觉-语言对齐**
   - 目标：视觉与语言模态对齐
   - 方法：仅训练 MLP 融合器，视觉编码器和 LLM 冻结
   - 数据：67B tokens（高质量图文对、OCR、世界知识）
2. **Stage-1：多模态预训练**
   - 目标：全参数端到端训练
   - 方法：全参数训练，混合视觉 Instruction 数据与纯文本数据
   - 数据：~1T tokens（含交错图文、视觉定位、VQA、STEM 数据及少量视频）
3. **Stage-2：长上下文预训练**
   - 目标：扩展上下文处理能力
   - 调整：序列长度增至 32768，增加纯文本比例和视频/任务数据
   - 数据：~1T tokens（强化长视频与多步骤任务理解）
4. **Stage-3：超长上下文适应**
   - 目标：突破上下文窗口极限
   - 调整：序列长度扩展至 262144
   - 数据：100B tokens（聚焦长视频/长文档分析任务）

2.2 数据来源

数据合成方法论：
1）强调模型标注（Qwen2.5VL 系列）的数据合成、过滤与验证。
2）合成数据与真实数据配比、多样性采样，平衡规模与质量。
3）多阶段处理流程（生成 → 验证），确保数据可靠性。
4）统一标注框架与标准化设计（如坐标、格式）提升泛化性。

- **图像-文本对数据（Image-Caption Pairs）**

使用Qwen2.5-VL-32B 模型对原始文本进行重新标注，生成更细粒度的描述（对象属性、空间布局等）。

基于视觉嵌入的聚类增强，对数据分布稀疏区域并进行定向增强。

- **交错文本-图像数据（Interleaved Text-Image）**

对（多模态）网页、书籍使用Qwen2.5-VL-7B（轻量级模型）进行多模态解析，精确对齐文本与图表/照片。

低价值内容过滤：移除纯文本/未对齐片段，要求最低页面数、图像-文本比例。

最终需要切分、合并为最长不超过 256K token 的序列。

- **知识实体数据（World Knowledge）**

百科数据，覆盖 10+ 语义类别（动物/植物/地标等）。

重要性采样策略：高显著性实体高频采样，低显著性实体低频保留。

使用 LLM 生成增强描述，包含视觉属性、空间关系和交互信息。

- **OCR 与文档解析**

OCR：30M 内部样本 + 30M 合成多语言样本，均使用 Qwen2.5-VL 标注。

文档解析：3M PDF + 4M 内部文档，使用布局模型预测阅读顺序，Qwen2.5-VL-72B 进行区域识别（类似PaddleOCR-VL）。

- **视觉定位与计数（Grounding and Counting）**

融合开源数据与合成数据构建框/点定位数据集，通过Qwen2.5-VL进行标注/低置信度过滤。

计数任务涵盖直接计数、先给出框/点再引导计数、[0,1000] 先坐标标准化后再计数三种形式。

- **空间与 3D 理解（Spatial Understanding and 3D Recognition）**

相比视觉定位与计数，3D 理解需要推理空间关系、功能推断（如“可抓握”“可按压”）以及可行动作序列（如“如何移动障碍物拿到书”），目标是为具身智能（Embodied AI）和交互系统提供基础，支持对 3D 场景的深层语义理解。

空间理解数据合成：融合真实场景与合成布局数据，通过模板和 LLM 生成多样化自然语言查询，强调相对空间关系表达（非绝对坐标）。

3D 定位数据合成：整合多源公共场景数据，构建单目图像 + 自然语言指代 +3D 边界框（9 自由度）的问答格式数据集。过滤遮挡/噪声标签，统一至虚拟相机坐标系（基于 Omni3D 方法），确保空间一致性。合成细粒度描述文本，涵盖物体属性、布局、空间位置及交互关系，提升指代表达精准度。

- **多模态代码能力（Code）**

复用 Qwen3-Coder 系列大规模代码语料。

开源整理 + 合成多模态 Coding 数据集：UI 转 HTML/CSS、SVG 生成、流程图转代码等。

- **视频理解（Video）**

在视频数据集的内容多样性上进行均衡采样。

FPS 动态采样策略：根据序列长度约束调整 fps 和最大帧数。

利用字幕模型进行密集标注，合成时间连贯的 caption label。

- **STEM 多模态推理（Science, Technology, Engineering, and Mathematics）**

使用代码生成图示的方法生成几何图表数据：1M 点标注样本 + 2M 视觉问答对，并使用 reward model 进行检查。

多模态推理：60M K-12/本科习题 + 12M 合成推理样本，通过拒绝采样仅保留具有挑战性的问题。

- **代理数据（Agent）**

GUI 交互数据涵盖跨平台界面感知与多步任务轨迹：在跨平台界面感知方面，通过元数据、解析工具和人

工标注构建了诸如元素描述、密集字幕生成和密集定位等任务，从而实现对多样化用户界面的稳健理解。在多步任务方面，通过一个自我演化的轨迹生成框架组装多步骤任务轨迹，并辅以针对性的人工审核。

函数调用通过合成 Pipeline 实现无需真实执行的数据合成：首先通过图像指导具备能力的模型生成用户查询及其对应的功能定义。接着我们采样模型的功能调用并生成其推理过程，并合成功能响应。该过程会不断重复，直到用户的查询被判断为已解决，剔除其中格式错误的轨迹。

搜索能力集成在线工具，支持长尾实体知识获取：通过在线图像搜索和文本搜索工具收集多模态事实查询轨迹，鼓励模型对不熟悉的实体进行搜索。通过这种方式，模型学会了从网络上收集信息，从而生成更加准确的响应。

3. 后训练

后训练流程分为三个阶段，旨在提升模型的指令遵循、推理能力及人类偏好对齐：

Stage 1：监督微调（SFT）

- 目标：激活指令遵循能力与潜在推理技能。
- 实现方式：
  - 两阶段训练：
    i. 初始阶段：基于 32k 上下文长度进行训练。
    ii. 扩展阶段：将上下文窗口扩展至 256k，专注于长文档和长视频数据的处理。
  - 数据分类：
    - 标准格式：适用于非思考模型（Instruct 模型）。
    - 思维链（CoT）格式：显式建模推理过程，适用于思考模型（Thinking 模型）。

Stage 2：强到弱蒸馏（Strong-to-Weak Distillation）

- 核心方法：通过知识蒸馏，将强教师模型的能力迁移至学生模型。
- 关键设计：
  - 纯文本数据微调：仅使用纯文本数据对 LLM 主干进行优化。
  - 效果：显著提升文本任务与多模态任务的推理能力。

Stage 3：强化学习（RL）

- 目标：增强模型性能与人类偏好对齐，优化细粒度能力。
- 子阶段划分：
  - 推理 RL：针对数学、OCR、基础推理等需逻辑推导的领域。
  - 通用 RL：覆盖多模态任务（如指令遵循、文本-图像对齐等）。

3.1 SFT

这部分方法是确定的，就是做 Instruction Tuning。关键在于数据构建，分为两个部分：Instruct 模型（非思考模型）数据构建、Thinking 模型（思考模型）数据构建。

Instruct 模型 SFT 数据

在Qwen2.5-VL的 8 大核心领域、30 个类别基础上进行拓展，新增空间推理（具身智能）、细粒度视觉理解、视频时空定位（目标追踪）及长上下文技术文档解析等类别的数据。

- **数据规模与组成**：SFT 数据集包含约 120 万样本，其中：
  - **单模态数据**（1/3）：纯文本数据条目。
  - **多模态数据**（2/3）：图像-文本对、视频-文本对，支持复杂场景解析。
- **分阶段训练**：为适配 256K token 长上下文能力，采用两阶段训练：

- **第一阶段**：32K token 序列长度，训练 1 个 epoch；
- **第二阶段**：256K token 全长度，混合长上下文数据与 32K token 样本（采用课程学习策略）。

采用 **两阶段过滤** 对查询（query）和响应（response）进行过滤，一方面需要保证查询足够清晰、可验证。另外一方面需要保证响应正确、无害。

- **查询过滤**：
  - 使用Qwen2.5-VL 过滤不可验证或模糊指令。
  - 修订歧义查询，保留语义意图。
  - 剔除低信息密度网络查询，保留高复杂度、高相关性样本。
- **响应过滤**：
  - **规则过滤（Rule-Based Filtering）**：去除重复、不完整、格式错误或有害内容。
  - **模型过滤（Model-Based Filtering）**：基于 Qwen2.5-VL 的奖励模型多维度评估。
    - **答案质量**：正确性、完整性、清晰度、实用性。
    - **视觉任务**：重点验证视觉信息利用的准确性。
    - **隐蔽问题检测**：识别语言混杂、风格突变等规则难以覆盖的缺陷。

思考模型 Long-CoT 冷启动数据

为了对 Thinking 模型进行冷启动 SFT，构建专门的长思维链（Long-CoT）冷启动数据集，其中多模态与纯文本数据 1:1 混合：

1. **数据构成**
   - 多模态数据（占比 50%）：聚焦视觉问答（VQA）、OCR、2D/3D 定位、视频分析等传统任务，强化 STEM 与智能体工作流相关的高阶推理能力。
   - 纯文本数据（占比 50%）：延续 Qwen3 的数据特征，覆盖数学、代码生成、逻辑推理等复杂学科领域。
2. **过滤低质、简单样本方法**
   - **难度校准**：我们选择性地保留基线模型通过率较低或生成较长、更详细回复的实例。这使得数据集中包含了对当前模型而言真正具有挑战性的问题。
   - **多模态必要性筛选**：通过 Qwen3-30B-nothink 模型过滤可仅凭文本解决的视觉数学问题，保证视觉输入的必要性。
   - **响应净化机制**：
     - 答案核对：优先剔除含错误答案的候选答案。
     - 过程核对：二次过滤存在重复表达、语言混杂、缺乏逻辑推演的猜测型回答。

3.2 Strong-to-Weak Distillation

Strong-to-Weak Distillation（强到弱蒸馏）流程是为了使用旗舰模型提升轻量级模型的性能：

- **Off-policy Distillation**：在第一阶段，直接使用 Teacher 模型输出 SFT 轻量级的 Student 模型，硬蒸馏。
- **On-policy Distillation**：在第二阶段，学生模型根据提供的提示生成响应，最小化 KL 散度来对齐学生模型和教师模型的预测结果（logits），软蒸馏。

3.3 RL

推理强化学习（Reasoning RL）

数据准备

- 来源：开源与私有数据，经严格预处理和人工标注确保质量，注意收集的问题都是可以被规则和代码验证的。

- 多模态数据筛选：通过预训练视觉语言模型采样 16 个响应，全错则丢弃查询；过滤通过率超 90% 的简单任务，混合多任务批次并预设任务样本比例。（类似 DAPO 的过滤策略）
- 实验筛选：通过初步 RL 实验剔除低潜力数据，最终保留约 3 万条多任务 query。

奖励设计

- 统一框架，对每一个任务单独设计 Reward，**这部分细节保密了**。
- 唯一提供的细节：通过提示控制输出格式，避免显式格式奖励；对语言切换（如非提示语言响应）施加惩罚。

RL 算法

- 采用 SAPO 算法（自适应策略梯度法，同样来自 Qwen 团队）。

通用强化学习（General RL）

> **目标：**
> 1）增强模型泛化能力与鲁棒性，纠正 SFT 阶段的错误先验知识（如反直觉计数、复杂时钟识别）。
> 2）抑制有害行为：语言混合、重复输出、格式错误（通过专用数据集高频惩罚优化）。

奖励机制

- 指令遵循：评估内容、格式、长度等约束的匹配度（如 JSON 结构化输出）。
- 偏好对齐：优化开放性任务的主观质量（有用性、事实性、风格适配性）。

混合奖励系统

- 规则奖励：针对可验证任务（如格式遵循），用明确启发式规则减少奖励欺骗风险。
- 模型奖励：Qwen2.5-VL-72B 或 Qwen3 作为 Reward Model 评估开放任务，减少严格规则导致的误判（如非标准但有效响应）。

3.4 Thinking with Images

按照之前"Thinking with images" 的思路，如果给 VLM 赋予 Agent 能力，能帮助其在 Reasoning 上进一步 Scaling，因此 Qwen3-VL 提出了一种两阶段训练范式，赋予 Qwen3-VL 视觉 Agent 能力：

1. **第一阶段**
   - 合成约 10k 冷启动基础数据集，主要包含两轮视觉问答任务（如 attribute detection）。
   - 通过监督微调 (SFT) 训练 Qwen2.5-VL-32B，模拟" 思考 → 行动 → 反馈分析 → 回答" 的 Agent 行为。
   - 采用**multi-turn,tool-integrated**强化学习 (RL) 增强推理能力。
2. **第二阶段**
   - 通过第一阶段模型生成更大规模的 120k 多轮交互数据集。
   - 结合合成与蒸馏数据，采用类似 SFT+RL 流程进行后训练。

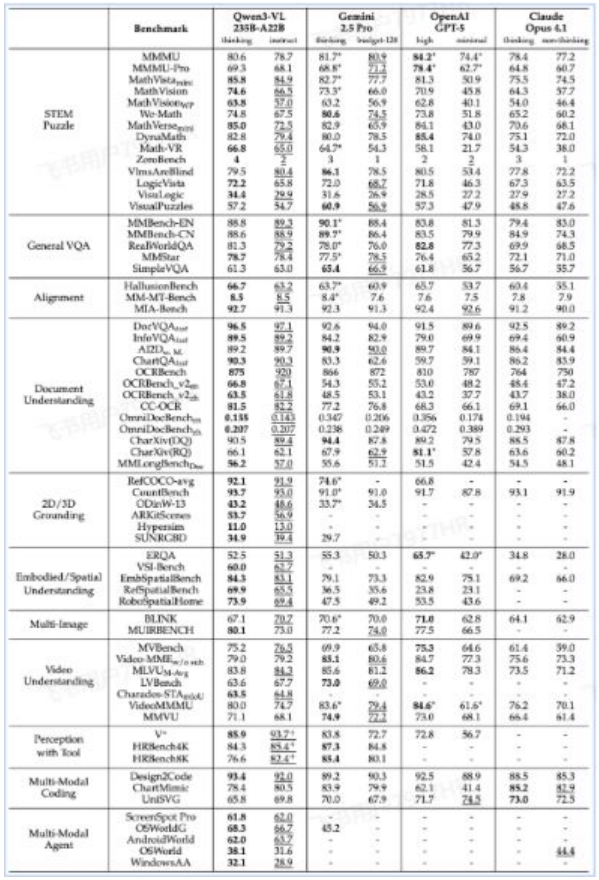
两个阶段共享奖励设计（唯独数据不同）：

- **答案准确度奖励**：基于 Qwen3-32B 评估最终答案正确性。
- **多轮推理奖励**：通过 Qwen2.5-VL-72B 验证工具反馈解析与分步推理的连贯性。
- **工具调用奖励**：动态匹配工具使用次数与专家预估目标值（由 Qwen2.5-VL-72B 离线评估任务复杂度确定），早期的实验表明，模型倾向于退化为仅调用一次工具来获取前两个奖励，而不管任务需求如何。为了缓解这一问题，我们明确地将工具调用奖励纳入其中，以促进与任务复杂度相适应的工具探索。

4. 实验

通用视觉问答（VQA）

- Qwen3-VL 系列在不同规模模型（2B 至 235B 参数）中均展现竞争力。旗舰模型 Qwen3-VL-235B-A22B-Thinking 在 MMStar 基准测试中达到 78.7 分，达到 SOTA。
- 中小型模型（如 32B）在 RealWorldQA 等任务中超越 Gemini 2.5 Flash、GPT-5 Mini 模型，显示良好的扩展性。
- **可以参考 Gemini-3-Pro 官网的 benchmark 得分，感觉差距还是有点大的，我指的是不如 Gemini-3-Pro。**



	Benchmark	Qwen3-VL 235B-A22B		Gemini 2.5 Pro		OpenAI GPT-5		Claude Opus 4.1	
		thinking	instruct	thinking	budget-128	high	minimal	thinking	non-thinking
STEM Puzzle	MMMU	80.6	78.7	81.7*	80.9	**84.2***	74.4*	78.4	77.2
	MMMU-Pro	69.3	68.1	68.8*	77.2	**78.4***	62.7*	64.8	60.7
	MathVista$_{mini}$	**85.8**	84.9	82.7*	77.7	81.3	50.9	75.5	74.5
	MathVision	**74.6**	66.5	73.3*	66.0	70.9	45.8	64.3	57.7
	MathVision$_{WE}$	**63.8**	57.0	63.2	56.9	62.8	40.1	54.0	46.4
	We-Math	74.8	67.5	**80.6**	74.5	73.8	51.8	65.2	60.2
	MathVerse$_{mini}$	**85.0**	72.5	82.9	65.9	84.1	43.0	70.6	68.1
	DynaMath	82.8	79.4	80.0	78.5	**85.4**	74.0	75.1	72.0
	Math-VR	**66.8**	65.0	64.7*	54.3	58.1	21.7	54.3	38.0
	ZeroBench	4	2	3	1	2	2	3	1
	VlmsAreBlind	79.5	80.4	**86.1**	78.5	80.5	53.4	77.8	72.2
	LogicVista	**72.2**	65.8	72.0	68.7	71.8	46.3	67.3	63.5
	VisuLogic	**34.4**	25.9	31.6	26.9	28.5	27.2	27.9	27.2
	VisualPuzzles	57.2	54.7	**60.9**	56.9	57.3	47.9	48.8	47.6
General VQA	MMBench-EN	88.8	89.3	**90.1***	88.4	83.8	81.3	79.4	83.0
	MMBench-CN	88.6	88.9	**89.7***	86.4	83.5	79.9	84.9	74.3
	RealWorldQA	81.3	79.2	78.0*	76.0	**82.8**	77.3	69.9	68.5
	MMStar	**78.7**	78.4	77.5*	78.5	76.4	65.2	72.1	71.0
	SimpleVQA	61.3	63.0	**65.4**	66.9	61.8	56.7	56.7	55.7
Alignment	HallusionBench	**66.7**	63.2	63.7*	60.9	65.7	53.7	60.4	55.1
	MM-MT-Bench	**8.5**	8.5	8.4*	7.6	7.6	7.5	7.8	7.9
	MIA-Bench	**92.7**	91.3	92.3	91.3	92.4	92.6	91.2	90.0
Document Understanding	DocVQA$_{test}$	**96.5**	97.1	92.6	94.0	91.5	89.6	92.5	89.2
	InfoVQA$_{test}$	**89.5**	89.2	84.2	82.9	79.0	69.9	69.4	60.9
	AI2D$_{w.M.}$	89.2	89.7	**90.8**	90.0	89.7	84.1	86.4	84.4
	ChartQA$_{test}$	**90.3**	90.3	83.3	62.6	59.7	59.1	86.2	83.9
	OCRBench	**875**	920	866	872	810	787	764	750
	OCRBench_v2$_{en}$	**66.8**	67.1	54.3	55.2	53.0	48.2	48.4	47.2
	OCRBench_v2$_{zh}$	**63.5**	61.8	48.5	53.1	43.2	37.7	43.7	38.0
	CC-OCR	**81.5**	82.2	77.2	76.8	68.3	66.1	69.1	66.0
	OmniDocBench$_{en}$	**0.155**	0.143	0.347	0.206	0.356	0.174	0.194	-
	OmniDocBench$_{zh}$	**0.207**	0.207	0.238	0.249	0.472	0.389	0.293	-
	CharXiv(DQ)	90.5	89.4	**94.4**	87.8	89.2	79.5	88.5	87.8
	CharXiv(RQ)	66.1	62.1	67.9	62.9	**81.1***	57.8	63.6	60.2
	MMLongBench$_{Doc}$	**56.2**	57.0	55.6	51.2	51.5	42.4	54.5	48.1
2D/3D Grounding	RefCOCO-avg	**92.1**	91.9	74.6*	-	66.8	-	-	-
	CountBench	**93.7**	93.0	91.0*	91.0	91.7	87.8	93.1	91.9
	ODinW-13	**43.2**	48.6	33.7*	34.5	-	-	-	-
	ARKitScenes	**53.7**	56.9	-	-	-	-	-	-
	Hypersim	**11.0**	13.0	-	-	-	-	-	-
	SUNRGBD	**34.9**	39.4	29.7	-	-	-	-	-
Embodied/Spatial Understanding	ERQA	52.5	51.3	55.3	50.3	**65.7***	42.0*	34.8	28.0
	VSI-Bench	**60.0**	62.7	-	-	-	-	-	-
	EmbSpatialBench	**84.3**	83.1	79.1	73.3	82.9	75.1	69.2	66.0
	RefSpatialBench	**69.9**	65.5	36.5	35.6	23.8	23.1	-	-
	RoboSpatialHome	**73.9**	69.4	47.5	49.2	53.5	43.6	-	-
Multi-Image	BLINK	67.1	70.7	70.6*	70.0	**71.0**	62.8	64.1	62.9
	MUIRBENCH	**80.1**	73.0	77.2	74.0	77.5	66.5	-	-
Video Understanding	MVBench	75.2	76.5	69.9	65.8	**75.3**	64.6	61.4	39.0
	Video-MME$_{w/o\ sub.}$	79.0	79.2	**83.1**	80.6	84.7	77.3	75.6	73.3
	MLVU$_{M\text{-}Avg}$	83.8	84.3	85.6	81.2	**86.2**	78.3	73.5	71.2
	LVBench	63.6	67.7	**73.0**	69.0	-	-	-	-
	Charades-STA$_{mIoU}$	**63.5**	64.8	-	-	-	-	-	-
	VideoMMMU	80.0	74.7	83.6*	79.4	**84.6***	61.6*	76.2	70.1
	MMVU	71.1	68.1	**74.9**	72.3	73.0	68.1	66.4	61.4
Perception with Tool	V*	**85.9**	93.7†	83.8	72.7	72.8	56.7	-	-
	HRBench4K	84.3	85.4†	**87.3**	84.8	-	-	-	-
	HRBench8K	76.6	82.4†	**85.4**	80.1	-	-	-	-
Multi-Modal Coding	Design2Code	**93.4**	92.0	89.2	90.3	92.5	88.9	88.5	85.3
	ChartMimic	78.4	80.5	83.9	79.9	62.1	41.4	**85.2**	82.9
	UniSVG	65.8	69.8	70.0	67.9	71.7	74.5	**73.0**	72.5
Multi-Modal Agent	ScreenSpot Pro	**61.8**	62.0	-	-	-	-	-	-
	OSWorldG	**68.3**	66.7	45.2	-	-	-	-	-
	AndroidWorld	**62.0**	63.7	-	-	-	-	-	-
	OSWorld	**38.1**	31.6	-	-	-	-	-	44.4
	WindowsAA	**32.1**	28.9	-	-	-	-	-	-

	Benchmark	Qwen3-VL 30B-A3B		Qwen3-VL 32B		Gemini 2.5 Flash		GPT-5 mini	
		thinking	instruct	thinking	instruct	thinking	non-thinking	high	minimal
STEM Puzzle	MMMU	76.0	74.2	78.1	76.0	77.7	76.3	**79.0**	67.9
	MMMU-Pro	63.0	60.4	**68.1**	65.3	67.2	65.9	67.3	53.7
	MathVista$_{mini}$	81.9	80.1	**85.9**	83.8	79.4	75.3	79.1	59.6
	MathVision	65.7	60.2	70.2	63.4	64.3	60.7	**71.9**	46.6
	MathVision$_{WE}$	**58.9**	52.3	58.6	54.6	53.6	49.0	56.6	42.8
	We-Math	70.0	56.9	**71.6**	63.3	53.9	60.3	70.2	51.4
	MathVerse$_{mini}$	79.6	70.2	**82.6**	76.8	77.7	75.9	78.8	36.5
	DynaMath	80.1	73.4	**82.0**	76.7	75.9	69.7	81.4	71.3
	Math-VR	61.7	61.3	**62.3**	59.8	58.8	54.7	58.2	26.4
	ZeroBench	0	0	2	1	1	**3**	3	2
	VlmsAreBlind	72.5	67.5	85.1	**87.0**	77.5	75.9	75.8	62.0
	LogicVista	65.8	53.5	70.9	62.2	67.3	60.0	**71.4**	50.8
	VisuLogic	26.6	23.0	**32.4**	29.7	31.0	23.3	27.2	27.6
	VisualPuzzles	52.0	46.2	54.7	53.2	41.4	45.0	**59.3**	48.2
General VQA	MMBench-EN	87.0	86.1	**89.5**	87.6	87.1	86.6	86.6	78.5
	MMBench-CN	85.9	85.3	**89.4**	87.7	87.3	86.0	84.0	76.3
	RealWorldQA	77.4	73.7	78.4	**79.0**	76.0	75.7	**79.0**	73.3
	MMStar	75.5	72.1	**79.4**	77.7	76.5	75.8	74.1	61.3
	SimpleVQA	54.3	52.7	55.4	56.9	**63.2**	59.2	56.8	50.3
Alignment	HallusionBench	66.0	61.5	**67.4**	63.8	63.5	59.1	63.2	55.9
	MM-MT-Bench	7.9	8.0	8.3	**8.4**	8.1	8.0	7.7	7.4
	MIA-Bench	91.6	91.2	**92.3**	91.8	91.1	90.6	92.0	**92.3**
Document Understanding	DocVQA$_{test}$	95.5	95.0	96.1	**96.9**	92.8	93.0	90.5	90.6
	InfoVQA$_{test}$	85.6	81.8	**89.2**	87.0	82.5	81.7	77.6	72.8
	AI2D$_{w.M.}$	86.9	85.0	88.9	**89.5**	88.7	87.7	88.2	82.9
	ChartQA$_{test}$	**89.4**	86.8	89.0	88.5	60.6	69.0	57.5	57.8
	OCRBench	839	**903**	855	895	853	864	821	807
	OCRBench_v2$_{en}$	62.6	63.2	**68.4**	67.4	52.2	50.6	52.6	45.7
	OCRBench_v2$_{zh}$	60.4	57.8	**62.1**	59.2	43.8	43.9	45.1	41.0
	CC-OCR	77.8	**80.7**	79.6	80.3	75.4	74.8	70.8	61.6
	OmniDocBench$_{en}$	0.165	0.183	**0.148**	0.151	0.265	0.228	0.181	0.260
	OmniDocBench$_{zh}$	**0.233**	0.253	0.236	0.239	0.245	0.305	0.316	0.425
	CharXiv(DQ)	86.9	85.5	90.2	**90.5**	90.1	85.5	89.4	78.6
	CharXiv(RQ)	56.6	48.9	65.2	62.8	61.7	60.1	**68.6**	48.9
	MMLongBench$_{Doc}$	47.4	47.1	54.6	**55.4**	49.0	44.6	50.3	39.6
2D/3D Grounding	RefCOCO-avg	89.3	89.7	91.1	**91.9**	-	-	-	-
	CountBench	90.0	89.8	94.1	**94.9**	86.0	83.7	91.0	84.1
	ODinW-13	42.3	**47.5**	41.8	46.6	-	-	-	-
	ARKitScenes	55.6	**56.1**	46.1	55.6	-	-	-	-
	Hypersim	11.4	12.5	12.5	**14.0**	-	-	-	-
	SUNRGBD	34.6	**38.1**	33.9	37.0	-	-	-	-
Embodied/Spatial Understanding	ERQA	45.3	43.0	52.3	48.8	-	-	**54.0**	45.8
	VSI-Bench	56.1	**63.2**	61.2	61.5	-	-	31.5	30.5
	EmbSpatialBench	80.6	76.4	**82.7**	81.5	-	-	80.7	72.1
	RefSpatialBench	54.2	53.1	**67.2**	61.4	-	-	9.0	4.0
	RoboSpatialHome	65.5	62.9	**74.2**	64.6	-	-	54.3	44.6
Multi-Image	BLINK	65.4	67.7	**68.5**	67.3	68.1	66.8	-	56.7
	MUIRBENCH	77.6	62.9	**80.3**	72.8	72.7	67.5	-	57.5
Video Understanding	MVBench	72.0	72.3	**73.2**	72.8	-	-	-	-
	Video-MME$_{w/o\ sub.}$	73.3	74.5	77.3	76.6	**79.6**	75.6	78.9	71.0
	MLVU$_{M\text{-}Avg}$	78.9	81.3	82.3	82.1	82.1	77.8	**83.3**	71.7
	LVBench	59.2	62.5	62.6	63.8	**64.5**	62.2	-	-
	Charades-STA$_{mIoU}$	62.7	**63.5**	62.8	61.2	-	-	-	-
	VideoMMMU	75.0	68.7	79.0	71.9	73.9	65.2	**82.5***	56.7
	MMVU	66.1	59.8	67.9	66.8	**69.8**	68.2	**69.8**	64.8
Perception with Tool	V*	81.2	89.5†	84.8	**91.1**†	-	-	78.6	63.9
	HRBench4K	77.8	82.5†	82.1	**84.6**†	-	-	78.6	66.3
	HRBench8K	71.3	79.3†	74.8	**81.6**†	-	-	74.4	60.9
Multi-Modal Agent	ScreenSpot Pro	57.3	**60.5**	57.1	57.9	-	-	-	-
	OSWorldG	59.6	61.0	64.0	**65.1**	-	-	-	-
	AndroidWorld	55.0	54.3	**63.7**	57.3	-	-	-	-
	OSWorld	30.6	30.3	**41.0**	32.6	-	-	-	-
	WindowsAA	24.2	24.9	**42.9**	30.9	-	-	-	-

多模态推理

- 旗舰模型在数学、逻辑等 STEM 任务（如 MathVista、MathVision、ZeroBench）中表现领先，非思考模式（Instruct）和思考模式（Thinking）均优于同类模型。
- 中小型模型（如 32B）在复杂推理任务上显著优于前代 Qwen2.5-VL-72B，并超越 Gemini-2.5-Flash 和 GPT-5-mini。