DeepSeek VL2

> 支持动态分辨率和极端图片长宽比（found in InfographicVQA, dense OCR, and detailed visual grounding tasks）

1. 模型架构

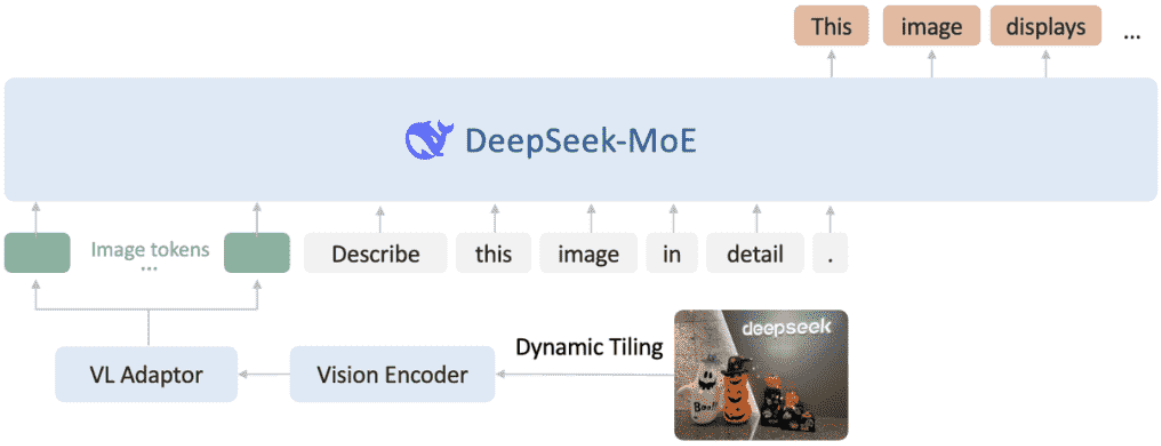


Figure 2 | **Overview of DeepSeek-VL2.** The overall structure is a llava-style architecture, which includes a vision encoder, a VL adaptor, and a MoE-based LLM.

采用的仍然是 MLLM 主流的 Vision Encoder（预训练）+Adaptor 桥接 +LLM 的模型结构。说实话现在 MLLM 结构基本收敛了（除了 InternVL-Xcomposer 等会有一些小改动），完全不像从前Flamingo那么复杂。

值得注意的点是语言模型使用的是 DeepSeek V2 的 MOE 模型：

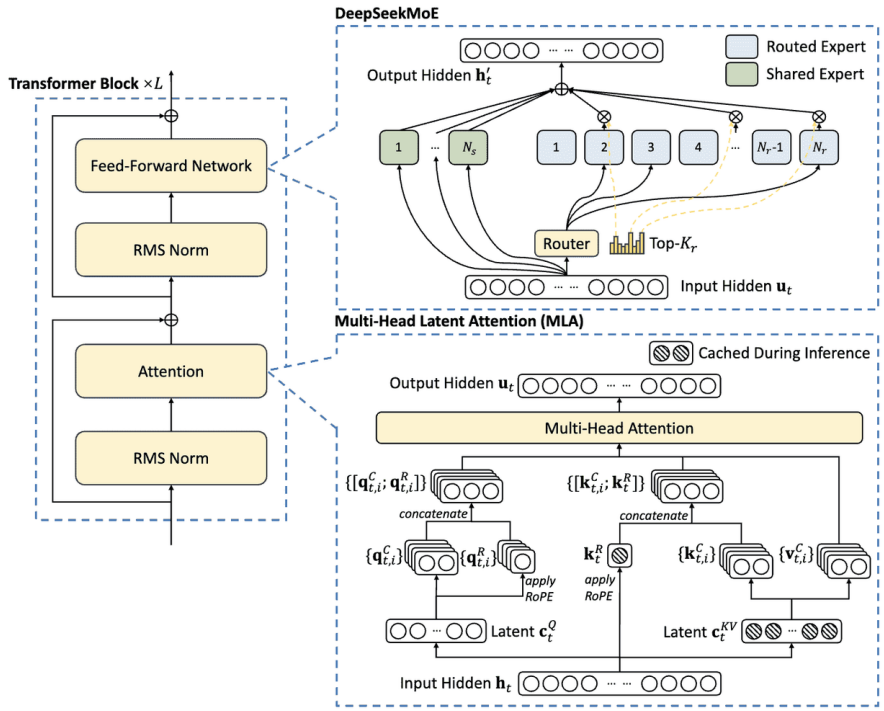


Figure 2 | Illustration of the architecture of DeepSeek-V2. MLA ensures efficient inference by significantly reducing the KV cache for generation, and DeepSeekMoE enables training strong models at an economical cost through the sparse architecture.

Vision Encoder

相比于DeepSeek VL的 Hybrid Vision Encoder，DeepSeek-VL2 **仅使用一个** SigLIP-SO400M 作为图像编码器。

> - SigLIP-SO400M
>
> **模型架构：**SoViT，结构和 ViT 一致，但是专注于计算预算一定情况下，对 hidden_dim、width、num_layers 进行 scaling。SoViT 的形状优化基于以下公式：$x_k^* = \left(\frac{\alpha_k a_k t^c}{\beta_k b_k}\right)^{\frac{1}{b_k + a_k}}$. 其中，$x_k^*$ 表示最佳形状参数（宽度、深度或 MLP 维度），t 为计算预算，c 为数据扩展指数。
> **训练方式：**SigLIP-SO400M 使用的是前文 (DeepSeek VL-1) 介绍的 SigLIP 训练方式，其相比与 CLIP 在 loss (CLIP 为 InfoNCE) 上进行了优化：
>
> $$-\frac{1}{|\mathcal{B}|}\sum_{i=1}^{|\mathcal{B}|}\sum_{j=1}^{|\mathcal{B}|}\underbrace{\log\frac{1}{1+e^{z_{ij}(-t\mathbf{x}_i\cdot\mathbf{y}_j+b)}}}_{\mathcal{L}_{ij}}$$
>
> 主要优化了两点：1）CLIP 由于需要 batch 的 scale，分布式训练时候一次前向需要两次 all reduce，sigLIP 只需要一次。2）偏置 b 缓解了正负样本不均衡问题。

SigLIP-SO400M 接收分辨率是 384*384，patch_size 为 14*14，输出 shape 为 (729, 1152)

Dynamic Tiling Strategy

其实就是参考了 LlavaNext 的策略 (7)，图像除了 resize 后进行编码（global thumbnail tile），还会分割成若干 384*384 的 tile（local tile）进行编码，之后直接 concat 起来。**所以结合上面 SigLIP-SO400M 视觉编码器的讲解，每一个 tile 在编码后产生 27 × 27 = 729 个 embedding of 1152 dimensions。**

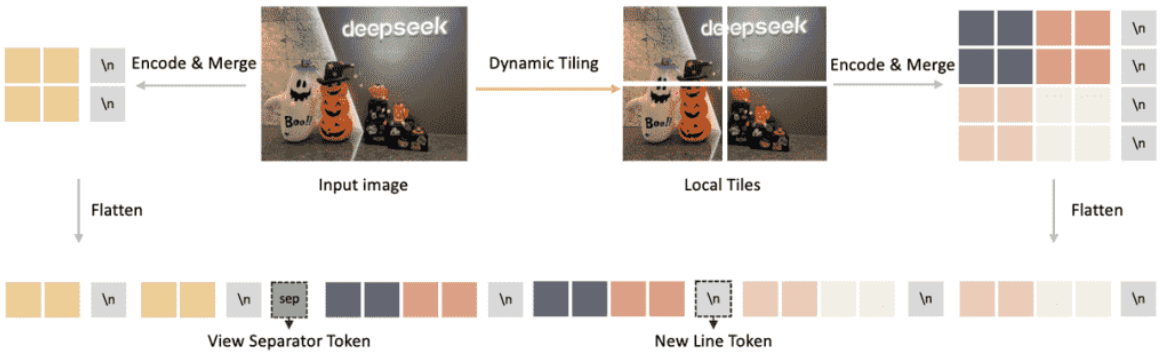


Figure 3 | **Illustration of dynamic tiling strategy in DeepSeek-VL2.** By dividing images into multiple tiles, DeepSeek-VL2 achieves stronger fine-grained understanding capabilities compared to DeepSeek-VL.

> 注意有一个细节，就是为了控制 seqence len，当输入图片数量大于 2 的时候是禁用 Dynamic Tiling Strategy 的！

注意：这里输出的 27×27 的 embedding 不是直接展开的！会经过 2 × 2 的 pixel shuffle operation 压缩到 14 × 14 = 196 个 tokens。然后是一些细节性的东西，就是对于两个分割 token（<tile_newline> 和 <view_separator>）的插入规则，我给大家总结为三点：

- 对于 global thumbnail tile，每一行自己的 embedding 遍历完插入一个 <tile_newline>
- 对于 local tile，每一行全局 embedding 遍历完插入一个 <tile_newline>
- global thumbnail tile 和 local tile 之间插入一个 <view_separator>

设 local tile 总共有 $m_i \times n_i$ 个，则 visual sequence length 为 $210 + 1 + m_i \cdot 14 \times (n_i \cdot 14 + 1)$

其中第一个 210 是 global tile 的 $14 \times 15 = 210$

Adaptor

两层 MLP 解决。

LLM

用的是 DeepSeek MOE 的架构。

Table 1 | **Architectural configuration for DeepSeek-VL2**. We list the hyperparameters of the architecture along with the details related to the mixture-of-expert training.

	DeepSeek-VL2-Tiny	DeepSeek-VL2-Small	DeepSeek-VL2
Vocabulary size	129,280	102,400	129,280
Embedding size	1,280	2,048	2,560
#Attention heads	10	16	32
#Layers	12	27	30
Attention	Multi-Head Attention	MLA (rank=512)	MLA (rank=512)
#Routed experts	64	64	72
#Shared experts	2	2	2
Top-K for expert selection	6	6	6
Routing function	Softmax	Softmax	Sigmoid
Expert correction bias	×	×	✓

2. 实验

case study 可以参考 deepseek 的 blog(8) 。

同 size 模型上表现是能打的。

Table 4 | **Comparison with state-of-the-art models on general QA and math-related multimodal benchmarks**. †: activated parameters of MoE model. *: evaluated in a different setting.

Model	#Params (Activated)	MMStar	AI2D (test)	MMMU (val)	MME	MMBench (sum)	MMBench (en test)	MMBench-V1.1 (cn test)	MMT-Bench	RealWorldQA	MathVista (testmini)
Closed Model											
GPT-4V [69]	-	56.0	89.4	63.1	1,927	81	80.2	80	64.3	61.4	58.1
GPT-4o [32]	-	63.9	94.2	69.1	2,329	83.4	82.1	82.2	65.5	75.4	63.8
Claude 3.5 Sonnet [5]	-	62.2	94.7	68.3	1,920	79.7	80.7	78.5	-	60.1	67.7
Gemini-1.5-Pro [81]	-	-	94.4	62.2	-	-	-	-	64.5	70.4	63.9
Open-source Model (0.5B - 3B)											
LLaVA-OV 0.5B [45]	0.9B	37.7	57.1	31.4	1,478	61.6	55.5	59.6	-	55.6	34.8
InternVL2-1B [16]	0.9B	45.7	64.1	35.4	1,794	65.4	60.7	61.6	49.5	50.3	37.7
MM 1.5-1B [107]	1B	-	59.3	35.8	1,611	-	-	-	-	53.3	37.2
DeepSeek-VL2-Tiny	1.0B†	45.9	71.6	40.7	1,915	73.3	69.2	68.3	53.2	64.2	53.6
MolmoE-1B [22]	1.5B†	-	86.4*	34.9	-	-	-	-	-	60.4	34
MiniCPM-V 2.0 [99]	2.8B	-	-	38.2	1,809	69.6	68.1	-	-	-	38.7
InternVL2-2B [16]	2.2B	49.8	74.1	36.3	1,877	73.2	70.9	69.6	50.4	57.3	46.3
Qwen2-VL-2B [88]	2.2B	48	74.4	41.1	1,872	74.9	73.5	72.2	54.5	62.9	47.8
MM 1.5-3B [107]	3B	-	65.7	37.1	1,798	-	-	-	-	56.9	44.4
DeepSeek-VL2-Small	2.8B†	57.0	80.0	48.0	2,123	82.3	80.3	79.3	62.9	65.4	60.7
Open-source Model (4B - 13B)											
Phi-3.5-Vision [1]	4.1B	47.5	78.1	43	-	76	66.1	72.1	53.6	53.6	43.9
InternVL2-4B [16]	4.1B	54.3	78.9	47.9	2,060	78.6	73.9	75.8	55.7	60.7	58.6
Aria-MoE [46]	4.3B†	-	-	54.9	-	-	-	-	-	-	66.1
MM 1.5-7B [107]	7B	-	72.2	41.8	1,861	-	-	-	-	62.5	47.6
LLaVA-OV 7B [45]	8.0B	-	81.4	48.8	1,998	80.8	-	-	-	66.3	63.2
Molmo-7B-O [22]	7.6B†	-	90.7*	39.3	-	-	-	-	-	67.5	44.5
MiniCPM-V2.6 [99]	8.0B	57.5	82.1	49.8 (CoT)	2,348 (CoT)	81.5	79.3	78.0	60.8	65.0	60.6
InternVL2-8B [16]	8.0B	61.5	83.8	51.8	2,210	81.7	81.2	79.4	60.0	64.4	58.3
Qwen2-VL-7B [88]	8.3B	60.7	83	54.1	2,327	83	80.5	80.7	63.7	70.1	58.2
Pixtral-12B [3]	12.4B	-	-	52.5 (CoT)	-	-	-	-	-	65.4	58 (CoT)
DeepSeek-VL 7B [59]	7.3B	-	-	36.6	-	73.2	-	-	-	-	-
DeepSeek-VL2	4.5B†	61.3	81.4	51.1	2,253	83.1	79.6	79.2	63.6	68.4	62.8

实现同等表现的情况下参数量级大约可以压缩至 0.5 倍。

