DeepSeek VL

> 优势：处理高分辨率图像（1024 x 1024），同时保持相对较低的计算开销。

1. 训练阶段

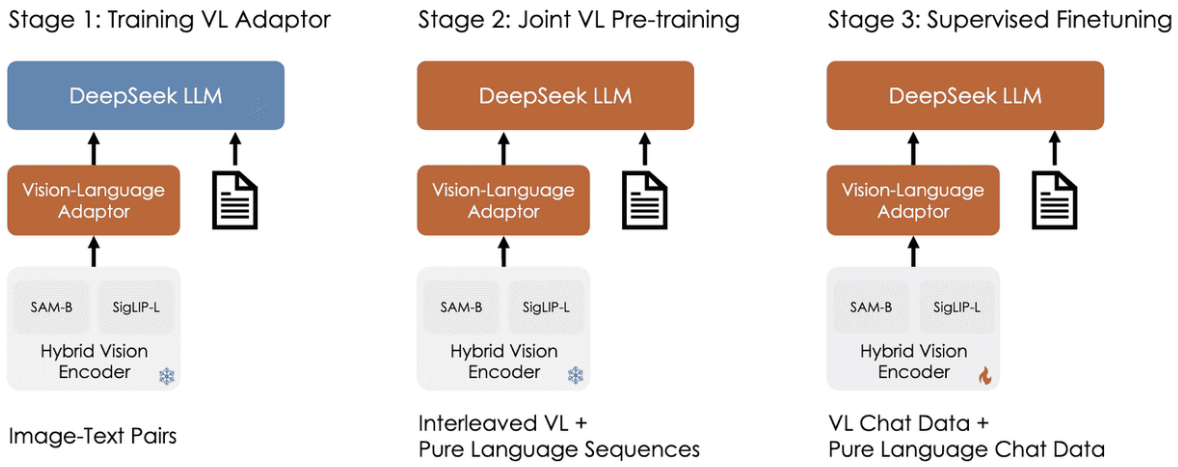


Figure 3 | Our training pipelines consist of three stages. Stage 1 involves training the Vision-Language (VL) adaptor while keeping the hybrid vision encoder and language model fixed. Stage 2 is the crucial part of the joint vision and language pretraining, where both VL adaptor and language model are trainable. Stage 3 is the supervised fine-tuning phase, during which the low-resolution vision encoder SigLIP-L, VL adaptor, and language model will be trained.

- Step 1: 训练 Adaptor，数据为 ShareGPT4V（125 万个图文 pair），以及 250 万个从文档 OCR 出来的图文 pair。
- Step 2: 放开 LLM 训练，利用 LLM zero-shot 能力对齐，以及用纯文本数据保持 LLM 语言能力，训练数据多模态数据：纯文本数据 =7：3。
- Step 3: 指令微调，SFT。

2. 模型结构

参考 Fig. 3，采用的是 MLLM 主流的 Vision Encoder（预训练）+Adaptor 桥接 +LLM 的模型结构。

2.1 Hybrid Vision Encoder

设计了一个 Hybrid Vision Encoder，使用两个不同分辨率的 ViT:

- SigLIP 的 ViT 接收 384*384 低分辨率的图像，用来提取粗粒度的图像信息；

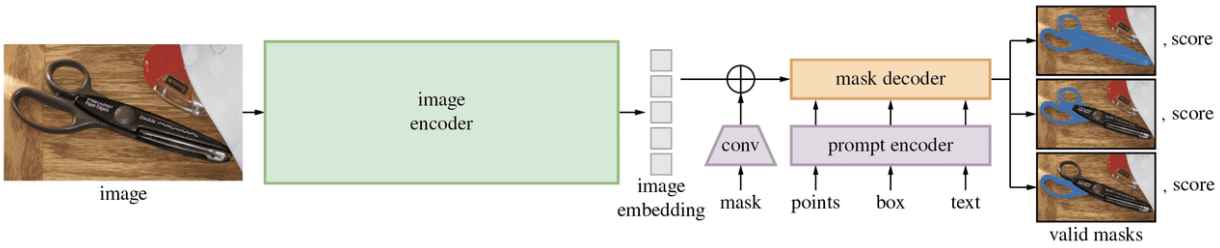
sigLIP 相比与 CLIP 在 loss (CLIP 为 InfoNCE) 上进行了优化：

$$-\frac{1}{|\mathcal{B}|}\sum_{i=1}^{|\mathcal{B}|}\sum_{j=1}^{|\mathcal{B}|}\underbrace{\log\frac{1}{1+e^{z_{ij}(-t\mathbf{x}_i\cdot\mathbf{y}_j+b)}}}_{\mathcal{L}_{ij}}$$

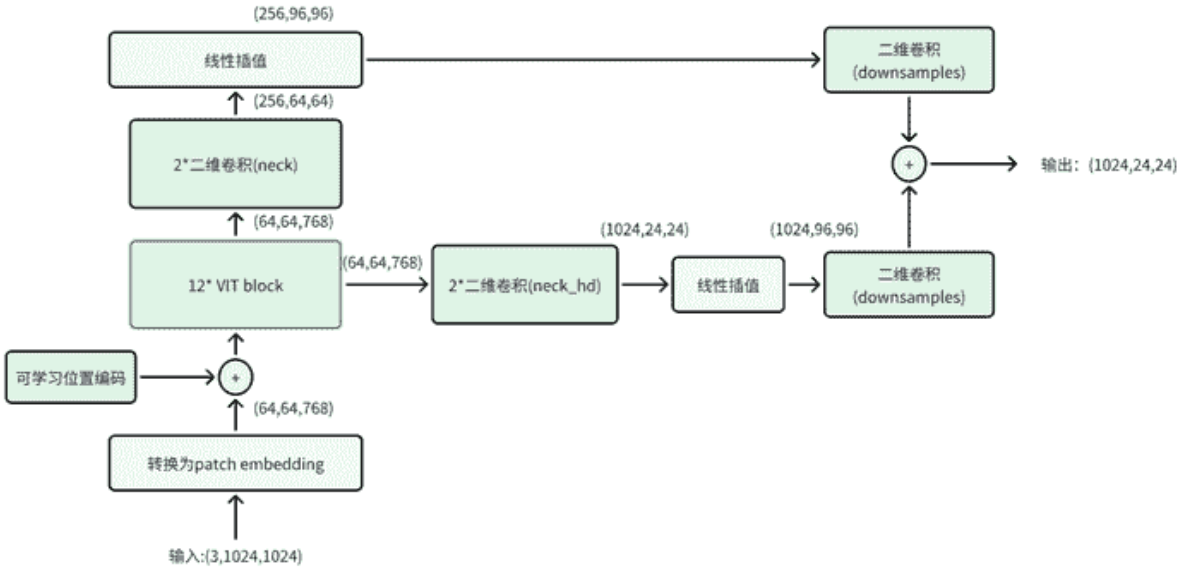
主要优化了两点：1）CLIP 由于需要 batch 的 scale，分布式训练时候一次前向需要两次 allreduce，sigLIP 只需要一次。2）偏置 b 缓解了正负样本不均衡问题。

SigLIP 的模型结构就是十分标准的 ViT，输入为 384*384，采用 16*16 的 patch，seq 长度为 24*24=576，采用 1024 个 kernel，输出为 (bs=1) 576*1024

- SAM-B 的 ViT 接收 1024*1024 的高分辨率图像，用来提取细粒度的图像信息；但是我看论文这个 ViT 是从 MAE 任务下 pretrain 的?



高分辨率模型 SAM（其实只有 SAM 的视觉编码器部分）的结构如下图所示，比 siglip 结构更复杂一些 (4)，输出为 (bs=1) 576*1024:



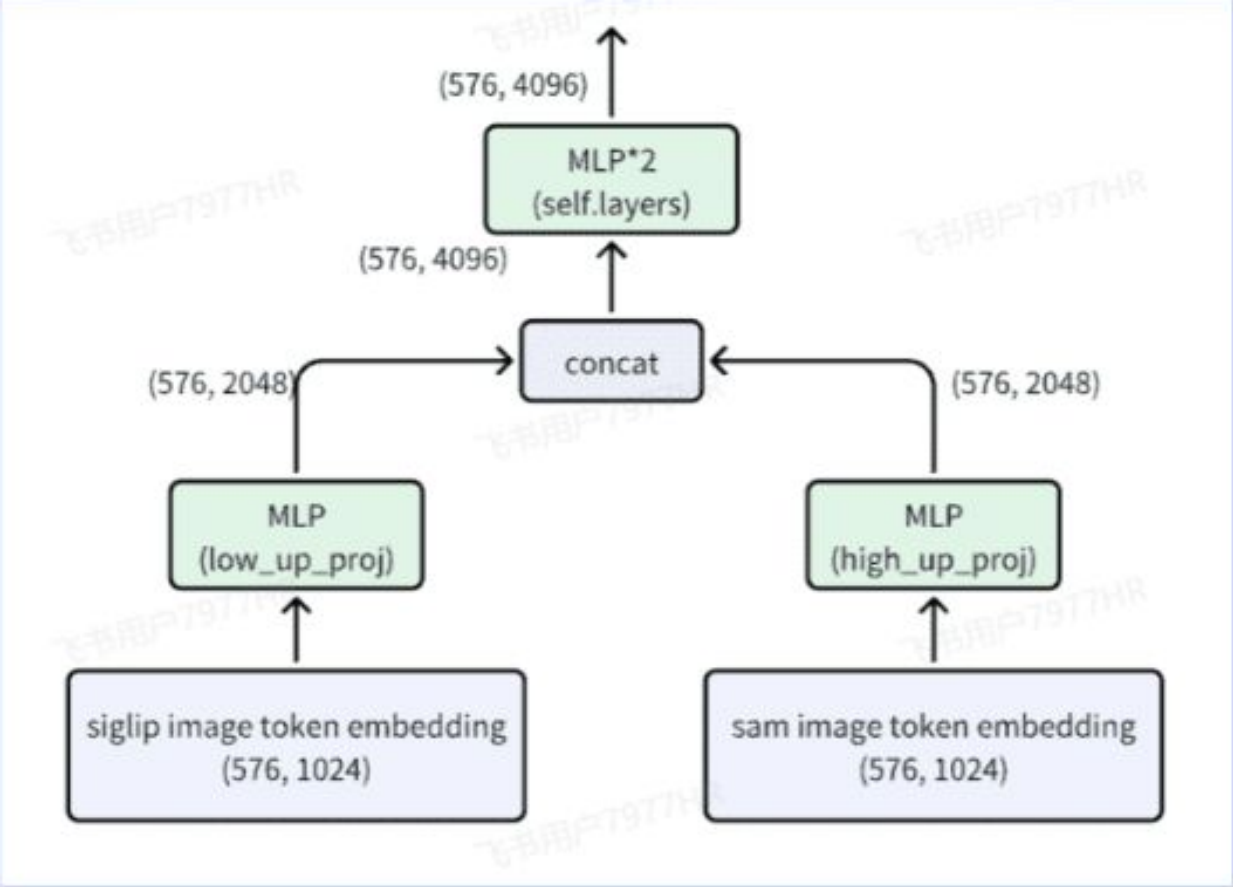
- SigLIP 和 SAM-VIT 特征融合

几种可选方式：dim 维度拼接、在序列维度拼接、embedding 相加、不处理。

DeepSeek 默认采用不处理，用 Adaptor 完成融合。

2.2 Adaptor

分别使用 siglip 和 SAM 的 VIT 结构得到图像的 token embedding（维度都为 (576,1024)）表示之后，需要使用适配器（由 MlpProjector 类实现）将图像 token embeding 映射到和文本 token embedding 对齐。具体结构如下：



2.3 LLM

用的是 deepseek 的语言模型基座。