input_ids

[B, S]

model · Qwen4ExpTextModel

≈125B

aux_input_ids

[B, S]

input_ids

[B, S]

[B, S]

Embedding

embed_tokens · 248320 → 2048 · 509M

[B, S, 2048]

layers · Qwen4ExpTextDecoderLayer

× 48

≈124B

ple_input_ids

hidden_states

ple · Qwen4ExpTextPLELayer

≈32.8M

[B, S]

input_ids

[B, S]

Qwen4ExpTextNGramEmbedding

ple_embedding

[B, S, 2048]

Linear

key_proj · 2048 → 8192 · 16.8M

[B, S, 8192]

Qwen4ExpTextRMSNorm

norm_key · 8192 · 8.19K

hidden_states

[B, S, 2048]

Linear

value_proj · 2048 → 2048 · 4.19M

Qwen4ExpTextRMSNorm

norm_query · 8192 · 8.19K

Sigmoid

Qwen4ExpTextRMSNorm

norm_conv · 8192 · 8.19K

Apply Padding Mask

Conv1d

conv1d · 8192 → 8192 · 32.8K

[B, S, 8192]

SiLU

output

Apply Padding Mask

Qwen4ExpTextGatedResidual

attn_hyper_connection · ≈6.30M

Qwen4ExpTextGatedResidual

mlp_hyper_connection · ≈6.30M

Qwen4ExpTextGatedDeltaNet

linear_attn · ≈50.0M

Qwen4ExpTextAttention

self_attn · 11.0M

Qwen4ExpTextSparseMoeBlock

mlp · 2.52B

hidden_states

Qwen4ExpTextGatedResidual

hyper_connection_final · 6.30M

last_hidden_state

Linear

lm_head · hidden_size → vocab_size

logits

Load Balancing Loss Func