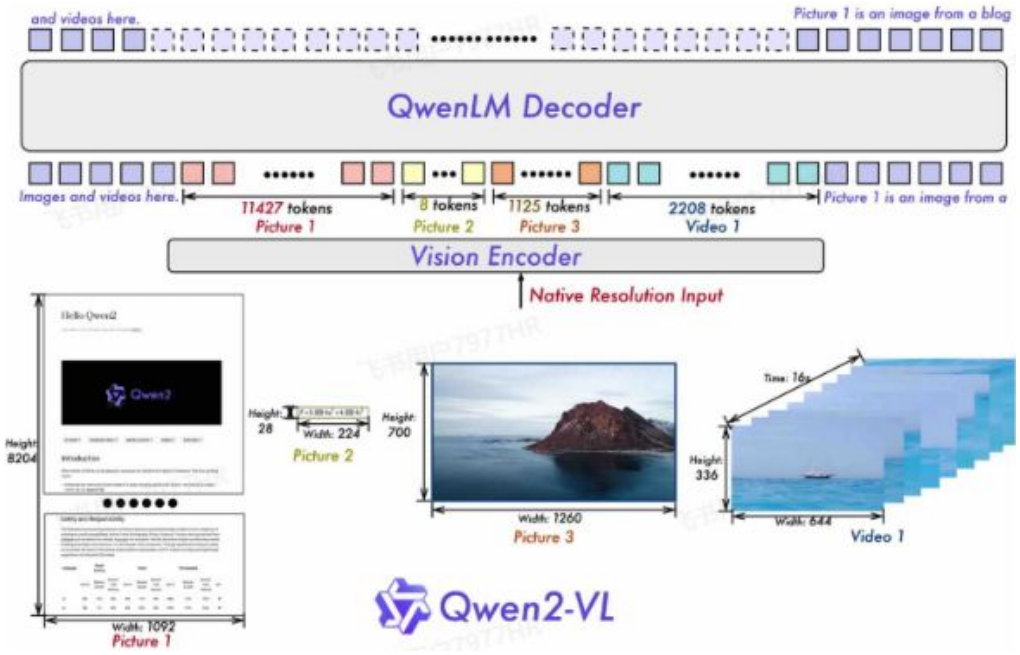
Qwen2-VL

来源：飞书原文

1. Architecture

一看图片，似乎没有 Adaptor 存在了，难道 Vision Encoder 出来的特征直接就送 LLM 了吗？(显然不是，MLP 藏在 Vision Encoder 里面了)



1.1 Vision Encoder

Qwen2-VL 支持动态分辨率（and 视频），这一点是通过 MRoPE (RoPE-2D) 实现的，也就是说扩充了允许 patch 的动态数量，也就自然而然支持动态分辨率了（当然，还是需要在 stage-1 训练时候训好 VE）。

ViT 参数从 DFN-ViT(2)（用的是 ViT 的绝对位置编码）初始化，替换 pos embedding 为 RoPE-2D。

- 2D-RoPE

把一维的 RoPE 转化为 2D-RoPE，其实就是在于 time 轴上其实只是简单复制 position embedding 而已，真正维护的 embedding 只是在单帧图片的二维平面上：

那究竟是怎么实现 2D 的呢，主要看这句：

所以实际上实现的做法就是：现在有一个 Pos Embedding 预计算表 PE，2D patch 定位是 (x,y)，那么我们需要的 pos embedding 就是 PE[x],PE[y] 在 dim 维度上 concat 一下。那么可能有的人会问，那维度怎么和 head_dim 对上，其实就在于预计算表 PE 是用 (head_dim//2) 来初始化的：

关于 2D-RoPE 的详细代码解析参考2D-RoPE

1.2 Adaptor

虽然结构图上没有 Adaptor，但是 Qwen 实质上用了两层 MLP 作为 Adaptor，只不过这个模块 PatchMerger 被放在了 VE 也就是 Qwen2VisionTransformerPretrainedModel 里面了：

只不过这里为了控制 seqlen，在 MLP 之前把相邻的 2*2 个 vision token 压缩成一个 (其实就是在 hidden_dim 上拼接)，之后再过双层 MLP (PatchMerger) 。

1.3 LLM

初始化于 Qwen2[3], 参数量：

Table 1: Model descriptions of Qwen2-VL.

Model Name	Vision Encoder	LLM	Model Description
Qwen2-VL-2B	675M	1.5B	The **most efficient** model, designed to run on-device. It delivers adequate performance for most scenarios with limited resources.
Qwen2-VL-7B	675M	7.6B	The **performance-optimized** model in terms of cost, significantly upgraded for text recognition and video understanding capabilities. It delivers significant performance across a broad range of visual tasks.
Qwen2-VL-72B	675M	72B	The **most capable** model, further improvements in visual reasoning, instruction-following, decision-making, and agent capabilities. It delivers optimal performance on most complex tasks.

- MRoPE



MRoPE 的简单示意图如上，简单理解就是 pos embedding 从 hidden_dim 上进行了分割，分别来表示 time、height、width，其实面试能答到这里已经足够了。但是秉持代码神一贯的解读代码作风，我们再来看一下具体实习，其实比上面复杂多了，参考MRoPE

2. Training

三阶段训练：

- Stage 1: 利用图像-文本对训练视觉编码器和连接层。使用了 600B 的 token（图像分类和 OCR 数据）。
- Stage 2: 训练所有参数。使用 800B token。这一阶段引入更高质量的混合图像-文本内容，包含多种任务和纯文本数据。
- Stage 3: 训练语言模型。数据包含多种任务 instructional datasets、agent 训练数据。

3. EXP

- 模型表现：

Table 6: Performance Comparison on Referring Expression Comprehension Task.

Type	Model	RefCOCO			RefCOCO+			RefCOCOg	
		val	test-A	test-B	val	test-A	test-B	val	test
Generalist	OFA-L (Wang et al., 2022)	80.0	83.7	76.4	68.3	76.0	61.8	67.6	67.6
	Shikra (Chen et al., 2023a)	87.0	90.6	80.2	81.6	87.4	72.1	82.3	82.2
	Qwen-VL (Bai et al., 2023b)	89.4	92.3	85.3	83.1	88.3	77.2	85.6	85.5
	Ferretv2 (Zhang et al., 2024a)	92.6	95.0	88.9	87.4	92.1	81.4	89.4	90.0
	CogVLM (Wang et al., 2023b)	92.8	94.8	89.0	88.7	92.9	83.4	89.8	90.8
	InternVL2$_{2b}$ (Chen et al., 2024c)	82.3	88.2	75.9	73.5	82.8	63.3	77.6	78.3
	InternVL2$_{8b}$ (Chen et al., 2024c)	87.1	91.1	80.7	79.8	87.9	71.4	82.7	82.7
	InternVL2$_{76b}$ (Chen et al., 2024c)	92.2	94.8	88.4	88.8	93.1	82.8	89.5	90.3
	Qwen2-VL$_{2b}$	87.6	90.6	82.3	79.0	84.9	71.0	81.2	80.3
	Qwen2-VL$_{7b}$	91.7	93.6	87.3	85.8	90.5	79.5	87.3	87.8
	Qwen2-VL$_{72b}$	**93.2**	**95.3**	90.7	**90.1**	**93.8**	**85.6**	**89.9**	**90.4**
Specialist	G-DINO-L (Liu et al., 2023c)	90.6	93.2	88.2	82.8	89.0	75.9	86.1	87.0
	UNINEXT-H (Yan et al., 2023)	92.6	94.3	**91.5**	85.2	89.6	79.8	88.7	89.4
	ONE-PEACE (Wang et al., 2023a)	92.6	94.2	89.3	88.8	92.2	83.2	89.2	89.3

video understanding tasks, and scaling up Qwen2-VL yields significant improvements. For the challenging Video-MME benchmark (Fu et al., 2024), which includes videos up to one hour, it is noteworthy that we limited the maximum number of frames extracted per video to 768 during evaluation, potentially impacting performance on longer videos. Future work will focus on extending Qwen2-VL to support longer sequences, thereby accommodating longer videos.

- Ablation

MRoPE 和 1D-RoPE 的对比：

Table 8: Ablation studies of M-RoPE. Compared to 1D-RoPE, using M-RoPE achieves better performance in downstream tasks, particularly in video benchmarks. RWQ means RealworldQA.

	Image Benchmarks								Video Benchmarks		
	MathVista	MMB	MMStar	RWQ	DocVQA	ChartQA	InfoVQA	TextVQA	PerceptionTest	NextQA	STAR
1D-RoPE	39.2	58.6	**36.7**	**54.5**	82.5	68.0	**50.8**	71.3	46.6	43.9	55.5
M-RoPE	**43.4**	**60.6**	**36.7**	53.7	**82.8**	**68.4**	50.3	**71.8**	**47.4**	**46.0**	**57.9**

以及一些比较有趣的观察，就是如果计算资源足够，那么在 test-time 时候做图片插值放大其实对效果是有提升的（一种 Test-Time Computing 的方向?）

Table 7: Qwen2-VL-7B under fixed/dynamic image tokens. Adjusting image sizes only results in small perturbations in performance, demonstrating the robustness to varying image sizes. Moreover, the dynamic resolution strategy achieves top-tier performance while consuming fewer tokens on average, demonstrating the efficiency of our model.

Strategy	Average Image Tokens	InfoVQA$_{val}$	RealWorldQA	OCRBench	MMMU
Fixed Image Tokens	64	28.85	56.47	572	53.33
	576	65.72	65.88	828	52.78
	1600	74.99	69.54	824	52.89
	3136	77.27	70.59	786	53.44
Dynamic Image Tokens	1924	75.89	70.07	866	53.44

4. Reference

[1] Wang P, Bai S, Tan S, et al. Qwen2-vl: Enhancing vision-language model's perception of the world at any resolution[J]. arXiv preprint arXiv:2409.12191, 2024.

[2] Fang A, Jose A M, Jain A, et al. Data filtering networks[J]. arXiv preprint arXiv:2309.17425, 2023.

[3] Yang A, Yang B, Hui B, et al. Qwen2 technical report[J]. arXiv preprint arXiv:2407.10671, 2024.