# MiniGPT-5(2023, UCSC)

论文：MiniGPT-5: Interleaved Vision-and-Language Generation via Generative Vokens
论文地址：https://arxiv.org/abs/2310.02239
项目地址：https://github.com/eric-ai-lab/MiniGPT-5

相比于多模态理解（看图说话），MiniGPT-5 则想着直接多模态同时生成（同时生成文本和图片）。

MiniGPT-5 本质可以理解为就是将 Stable Diffusion 中的 CLIP 文本编码器替换成 MiniGPT-4，从而实现文本、图像同时生成。

## 1. 模型结构

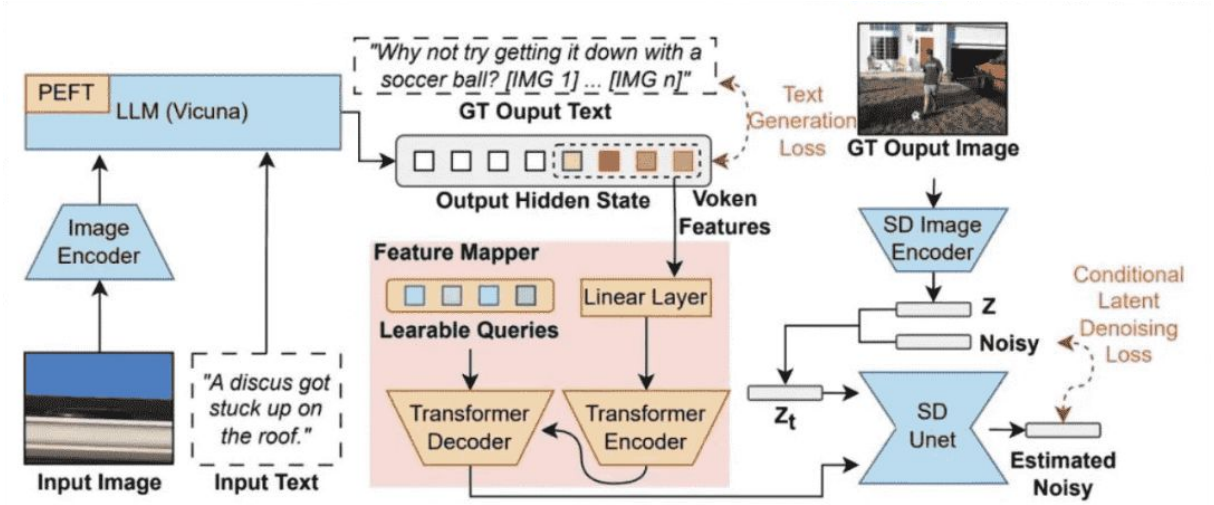



Figure 2: The overview structure of MiniGPT-5 pipeline. We leverage the pretrained multimodal large language model (MiniGPT-4) and text-to-image generation model (Stable Diffusion 2.1) to create a unified multimodal generation pipeline. The input image encoder includes a ViT, Qformer, and linear layer, pretrained by MiniGPT-4. The orange blocks include learnable parameters, while the blue blocks are fixed during training. More details can be find in Section 3.

### 1.1 多模态理解（Multimodal Understanding）模块

该部分的核心是一个预训练的多模态大语言模型（论文中使用的是 MiniGPT-4 作为基础），它可以将文本 token 与输入图像编码后的视觉特征拼接在一起，得到一序列特征表示，然后进行语言理解和生成。为了让 LLM 也能在“输出”时表达图像生成信息，作者在词表中增添了“Generative Vokens”（即 [IMG1]、[IMG2] ...这样的可学习 token），并在模型的输出层中加入对应的可学习向量，使得语言模型在生成序列时，可以自发地产生这些特殊 token，以此表征要生成的图像。

### 1.2 多模态生成（Multimodal Generation）模块

该部分的核心是一个预训练的文本-图像扩散生成模型（Stable Diffusion 2.1）。模型需要将从 LLM 输出层得到的“voken 特征”映射到 Stable Diffusion 的条件向量空间（比如 Stable Diffusion 的 text encoder 所在的维度）。当语言模型在输出序列中生成 [IMG1] 等“voken”时，就会将这些特殊 token 的隐藏表示传递到映射模块，再通过扩散模型完成图像的生成。

为了能够将 MiniGPT-4 和 Stable Diffusion 中 Unet 完美结合起来还需要对模型结构进行一定的修改：

- 为了 LLM 的词表添加了用来表示图像的 token，称为 generative vokens

- 为了将 MiniGPT-4 的输出 embedding 输入到 Unet，用一个 MLP+Transformer 进行了映射（上图中间红色框部分）

# 2. 模型训练

两阶段训练，Pretraining Stage 和 Fine-tuning Stage。

## 2.1 Stage 1：单图-单文本 Pretraining

第一阶段除了考虑文本生成的 loss、图像生成的 latent diffusion model loss，还要 SD 的文本编码器的输出对 generative vokens 进行了引导

使用像 CC3M 这样包含“图片 + 简短描述”对儿的大规模数据集。

训练目标：把语言模型的 voken 特征与 Stable Diffusion 的文本编码器特征对齐，从而让 MiniGPT-5 能够先学会根据“文本（caption）”来生成与描述一致的单张图像。

Loss：

$$L_{\text{Pretrain}} = \lambda_1 * L_{\text{text}} + \lambda_2 * L_{\text{LDM}} + \lambda_3 * L_{\text{CAP}}$$

其中

$$\mathcal{L}_{\text{CAP}} = \text{MSE}(\hat{h}_{\text{voken}}, \tau_\theta(c))$$

## 2.2 Stage 2：多图-多文本 Fine-tuning

第二阶段使用更复杂的数据和任务来进行微调，只考虑了文本生成的 loss 和图像生成的 loss

数据使用的是像 VIST、MMDialog 等包含多张图与多段文本交替的复杂对话或叙事数据。

训练目标：让模型能在长序列中，灵活地根据上下文生成文本和图像，并且能在恰当时机插入图像 [IMG] token。

Loss：

$$\mathcal{L}_{\text{Fine-tune}} = \lambda_1 \cdot \mathcal{L}\text{text} + \lambda_2 \cdot \mathcal{L}_{\text{LDM}}$$

因为训练涉及到图像生成，所以也用了 Classifier-free Guidance 来提升条件扩散模型的性能。