SigLIP2

论文：《SigLIP 2: Multilingual Vision-Language Encoders with Improved Semantic Understanding, Localization, and Dense Features》
论文链接：https://arxiv.org/pdf/2502.14786
GitHub：https://github. com/google-research/big_vision

1. 背景

SigLIP2 主要改进：

- 训练目标：在 SigLIP 的图像-文本 sigmoid 对比损失的基础上，结合了 LocCa 的基于解码器的预训练以及 SILC 和 TIPS 中的自蒸馏和掩码预测任务。
- 隐式蒸馏：并且通过主动样本选择进行隐式蒸馏，提升小型模型的性能。
- 可变分辨率：SigLIP2 包含一个 NaFlex 变体，支持多种分辨率并保留图像的原始长宽比。

通过这些改进，SigLIP 2 模型在所有模型规模上的核心能力均优于 SigLIP，包括零样本分类、图像-文本检索，以及在提取视觉-语言模型（VLMs）的视觉表示时的迁移性能。

2. SigLIP2

模型架构上还是 Image Encoder+Text Encoder 的架构，但是训练架构上有三个任务：

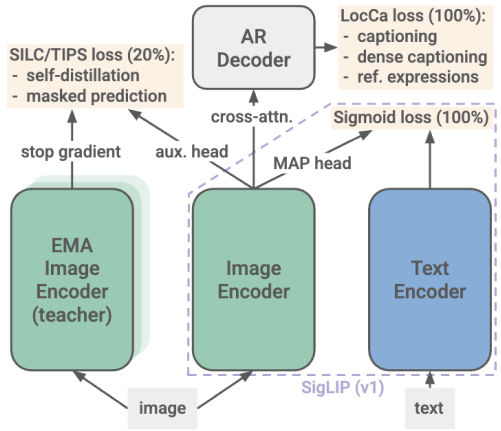


Figure 1 | SigLIP 2 adds the captioning-based pretraining from LocCa [62] as well as self-distillation and masked prediction from SILC [45] and TIPS [38] (during the last 20% of training) to the sigmoid loss from SigLIP [71]. For some variants, the recipe additionally involves fine-tuning with data curation [61] or adaptation to native aspect ratio and variable sequence length [6, 12].

2.1 Sigmoid Loss

这一部分和 SigLIP 是一样的。即 SigLIP 通过将每个图像嵌入与小批量中的每个文本嵌入组合，创建二元分类问题，并通过逻辑回归（sigmoid 损失）训练嵌入，以分类匹配和不匹配的对。

2.2 LocCa Loss

对于 LocCa，在未池化的视觉编码器表示（在应用 MAP 头之前）上附加了一个带有交叉注意力的标准 Transformer 解码器。解码器的结构与文本编码器相似，但增加了交叉注意力层，并将层数减少了一半。除了图

像描述生成，LocCa 还训练自动指称表达预测和基础描述生成。前者是预测描述特定图像区域的字幕的边界框坐标，而后者是给定边界框坐标预测区域特定的字幕。区域与字幕的配对通过首先从替代文本中提取 n-gram，然后使用 OWLv2 中的方法进行开放词汇检测来自动标注。此外，我们使用 PaLI 中固定的对象类别集，而不是 n-gram。对于每个示例，解码器被训练以预测所有三个目标（相当于三次解码器前向传递）。字幕生成目标以 50% 的概率通过并行预测进行预测，即所有字幕标记从掩码标记中并行预测，不使用因果注意力掩码。最后，为了减少由于大词汇量导致的内存消耗，实现分块版本的解码器损失。

2.3 SILC/TIPS Loss

SILC 和 TIPS 通过自蒸馏和掩码预测损失进行局部到全局的对应学习，以提升（未池化）特征表示的局部语义。这种表示通常用于像分割、深度估计等密集预测任务。

第一个项是来自 SILC 的局部到全局一致性损失，其中视觉编码器作为学生网络，仅获取训练图像的部分（局部）视图，并被训练来匹配从完整图像得出的教师表示。这个辅助匹配任务在一个用单独的 MLP 头计算的高维特征空间中执行。通常，教师的参数通过对学生参数在之前迭代中的指数移动平均（EMA）获得。我们依赖一个全局（教师）视图和 8 个局部（学生）视图，其他方面则遵循 SILC 中的增强、损失和超参数。

第二个损失项是来自 TIPS 的掩码预测目标。我们在学生网络中将 50% 的嵌入图像块替换为掩码标记，并训练学生在被掩盖的位置上匹配教师的特征。该损失的定义与第一个项（即一致性损失）相同，但应用于每个图像块的特征，而不是池化的图像级表示。此外，学生和教师都看到相同的全局视图（学生的视图会有掩码处理）。

在训练完成的 80% 时加入这些损失，将教师的参数初始化为学生的参数，而其余附加参数（如头部、掩码标记及相应的优化器参数）则随机初始化。我们使用原始图像计算上一节中的 SigLIP 和 LocCa 损失，并在额外增强的视图上应用附加损失。这样做是为了确保数据增强不会对图像-文本对齐产生负面影响，这也是 SILC 的建议。第一个和第二个损失项的权重分别设为 1 和 0.25。此外，为了平衡模型在全局/语义和密集任务上的质量，我们对这两个损失项分别按 0.25、0.5、1.0 和 0.5 的系数重新加权，适用于 B、L、So400m 和 g 模型大小。

2.4 可变尺寸和分辨率 (NaFlex)

针对多分辨率输入，SigLIP 2 采用了 NaFlex 模型，它结合了不同分辨率和保留图像原生纵横比的思想。该模型在处理图像时，首先调整输入图像的大小，以确保其高度和宽度在调整后是 patch 大小的倍数，同时尽量减少纵横比的失真。通过这种方法，可以使用适合不同类型图像的适当分辨率，并在任务中降低失真对性能的影响。

此外，NaFlex 支持多种预定义的序列长度，使得模型能够更有效地处理不同的输入类型。在训练阶段，模型从默认检查点开始，调整训练来适应变化的纵横比和分辨率，从而实现更好的处理和性能。

3. 实验

3.1 零样本分类和检索

SigLIP 2 在零样本分类（ImageNet、ObjectNet、ImageNetv2、ImageNet ReaL）和图文检索基准上的性能都优于 SigLIP 和其他（开放权重）基准。

需要注意的是，DFN 在这些基准上最接近 SigLIP 2，它使用在 ImageNet、COCO 和 Flickr 上微调的网络作为过滤器来提高数据质量。

由于蒸馏的原因，SigLIP2 在 B 尺寸模型上对基准的改进尤为显著。此外，我们观察到常见的缩放趋势是图像分辨率和模型大小的函数。

				ImageNet-1k					COCO		Flickr		XM3600	
ViT	Res.	Seq.	Model	val	v2	ReaL	ObjNet	10s.	T→I	I→T	T→I	I→T	T→I	I→T
B/32	224	49	MetaCLIP [66]	67.7	59.6	–	52.8	–	46.6	–	72.9	–	–	–
	256	64	OpenCLIP [27]	72.8	64.8	–	59.6	–	39.9	57.9	64.9	84.8	–	–
			SigLIP 2	**74.0**	**66.9**	**81.4**	**66.1**	**66.6**	**47.2**	**63.7**	**75.5**	**89.3**	**38.3**	**49.0**
B/16	224	196	CLIP [50]	68.3	61.9	–	55.3	–	33.1	52.4	62.1	81.9	–	–
			OpenCLIP [27]	70.2	62.3	–	56.0	–	42.3	59.4	69.8	86.3	–	–
			MetaCLIP [66]	72.4	65.1	–	60.0	–	48.9	–	77.1	–	–	–
			EVA-CLIP [57]	74.7	67.0	–	62.3	–	42.2	58.7	71.2	85.7	–	–
			SigLIP [71]	76.2	69.5	82.8	70.7	69.9	47.2	64.5	77.9	89.6	22.4	29.3
			DFN [19]	76.2	68.2	–	63.2	–	51.9	–	77.3	–	–	–
			SigLIP 2	78.2	71.4	84.8	73.6	72.1	52.1	68.9	80.7	93.0	40.3	50.7
	256	256	SigLIP [71]	76.7	70.1	83.1	71.3	70.3	47.4	65.1	78.3	91.1	22.5	29.9
			SigLIP 2	79.1	72.5	85.4	74.5	73.1	53.2	69.7	81.7	94.4	40.7	51.0
	384	576	SigLIP [71]	78.6	72.0	84.6	73.8	72.7	49.7	67.5	80.7	92.2	23.3	30.3
			SigLIP 2	80.6	73.8	86.2	77.1	74.7	54.6	**71.4**	83.8	94.9	41.2	51.6
	512	1024	SigLIP [71]	79.2	72.9	84.9	74.8	73.3	50.4	67.6	81.6	92.5	23.5	30.5
			SigLIP 2	**81.2**	**74.5**	**86.7**	**77.8**	**75.2**	**55.2**	71.2	**84.5**	**95.5**	**41.4**	**52.0**
L/14	224	256	OpenCLIP [27]	74.0	61.1	–	66.4	–	46.1	62.1	75.0	88.7	–	–
			CLIP [50]	75.5	69.0	–	69.9	–	36.5	56.3	65.2	85.2	–	–
			MetaCLIP [66]	79.2	72.6	–	74.6	–	55.7	–	83.3	–	–	–
			CLIPA-v2 [33]	79.7	72.8	–	71.1	–	46.3	**64.1**	73.0	89.1	–	–
			EVA-CLIP [57]	79.8	72.9	–	**75.3**	–	47.5	63.7	77.3	**89.7**	–	–
			DFN [19]	**82.2**	**75.7**	–	74.8	–	**59.6**	–	**84.7**	–	–	–
L/16	256	256	SigLIP [71]	80.5	74.2	85.9	77.9	76.8	51.2	69.6	81.3	92.0	30.9	40.1
			SigLIP 2	82.5	76.8	87.3	83.0	78.8	54.7	71.5	84.1	94.5	46.5	56.5
	384	576	SigLIP [71]	82.1	75.9	87.1	80.9	78.7	52.8	70.5	82.6	92.9	31.4	39.7
			SigLIP 2	83.1	77.4	87.6	84.4	79.5	**55.3**	71.4	85.0	95.2	47.1	56.3
	512	1024	SigLIP 2	**83.5**	**77.8**	**87.7**	**84.6**	**79.6**	55.2	**72.1**	**85.3**	**95.8**	**47.4**	**56.7**
So/14	224	256	SigLIP [71]	82.2	76.0	87.1	80.5	78.2	50.8	69.0	76.6	90.7	16.0	22.8
			SigLIP 2	83.2	77.7	87.8	84.6	79.5	55.1	71.5	84.3	94.6	47.9	57.5
	384	729	SigLIP [71]	83.2	77.1	87.5	82.9	79.4	52.0	70.2	80.5	93.5	17.8	26.6
			SigLIP 2	**84.1**	**78.7**	**88.1**	**86.0**	**80.4**	**55.8**	**71.7**	**85.7**	**94.9**	**48.4**	**57.5**
So/16	256	256	mSigLIP [71]	80.8	74.1	86.1	79.5	77.1	49.4	68.6	80.0	92.1	**50.0**	**62.8**
			SigLIP 2	83.4	77.8	87.7	84.8	79.7	55.4	**71.5**	84.4	94.2	48.1	57.5
	384	576	SigLIP 2	84.1	78.4	**88.1**	85.8	80.4	**56.0**	71.2	85.3	**95.9**	48.3	57.5
	512	1024	SigLIP 2	**84.3**	**79.1**	88.1	**86.2**	**80.5**	56.0	71.3	**85.5**	95.4	48.3	57.6
H/14	224	256	MetaCLIP [66]	80.5	74.1	–	76.5	–	57.5	–	85.0	–	–	–
			DFN [19]	**83.4**	**77.3**	–	**76.5**	–	**63.1**	–	**86.5**	–	–	–
g/16	256	256	SigLIP 2	84.5	79.2	88.3	87.1	82.1	55.7	72.5	85.3	95.3	48.2	**58.2**
	384	576	SigLIP 2	**85.0**	**79.8**	**88.5**	**88.0**	**82.5**	**56.1**	**72.8**	**86.0**	**95.4**	**48.6**	57.9

Table 1 | Zero-shot classification, 10-shot (10s) classification (on the validation set), and retrieval performance (recall@1) of SigLIP 2 along with several baselines. SigLIP 2 outperforms the baselines—often by a large margin—despite being multilingual. Note that DFN [19] relies on a data filtering network fine-tuned on ImageNet, COCO, and Flickr.

3.2 SigLIP2 作为 vlm 的视觉编码器

视觉编码器如 CLIP 和 SigLIP 的一个常见用途是为 VLMs 提取视觉表示。通常的做法是将预训练的视觉编码器与预训练的 LLM 结合，并在丰富的视觉语言任务混合上进行多模态训练。

具体来说，将 SigLIP 2 视觉编码器和基准与 Gemma2 2B LLM 结合，并在包含字幕、OCR、定向字幕、视觉问答、检测和实例分割的 Stage 1 训练集上的 5000 万例子上训练 LLM。我们保持视觉编码器冻结（这对质量几乎没有影响）并减少训练时间以反映典型的开放模型使用情况。生成的 VLM 随后在广泛的下游任务上进行微调，使用相关文献中的迁移设置。为了理解输入分辨率的影响，我们在分辨率 224 或 256（对应于分别提取 256 个图像 token 的 14 和 16 的 patch 大小的模型）和 384px 上进行实验，但与相关文献不同的是，我们在 384px 上重复 Stage 1，而不是从 224px 变体开始。

总体来看，SigLIP 2 在各个分辨率和模型大小上明显优于 SigLIP。对于 L 尺寸的视觉编码器，SigLIP 2 也优于最近发布的 AIMv2 模型。



Figure 4 | Comparison of different vision encoders after training a Gemma 2 LLM for 50M steps with a frozen vision encoder (PaliGemma [7] stage 1), followed by fine-tuning the VLM on individual datasets (PaliGemma stage 3). SigLIP 2 performs better than SigLIP and AIMv2 [20] for different model sizes and resolutions. Same data as in Table 6.