BEiT-v3(2023, Microsoft)

> BEiT-v3：大一统 (2023, Microsoft)
> Image as a Foreign Language: BEiT Pretraining for All Vision and Vision-Language Tasks

不论是在 Language、Vision 还是在多模态领域，Big Convergence 是大势所趋。

> 也就是在超大的数据集上做大规模的预训练，一旦模型训练好之后，它的特征就已经非常好了，可以直接 Transfer 到下游任务上去，尤其是当模型足够大、数据足够多的时候，有可能预训练出来一个有通用性能的 Foundation Model，这个 Foundation Model 能解决各种的模态或者各种下游任务，非常的强大。

相比之前的多模态模型如 CLIP 和 CoCa，**BEiT-v3 的关键词就是：Big Convergence 大一统**，即：**将图像看成一种“语言”**，用一个模型架构和一个训练任务，打造出多模态领域的集大成者，**统一多模态学习中的模型结构、预训练任务以及模型规模。**

A big convergence of language, vision, and multimodal pretraining is emerging，即视觉的表征，语言的表征和多模态的表征都在大一统。BEiT-v3 使用 Transformer 模型统一处理视觉和文本信息，使用 Mask Data Modeling 的训练策略统一建模视觉和文本信息。

BEiT-v3 从三个方面实现了大一统：

- **模型架构 Multiway Transformer**
  - 其实就是 VLMo 中 MoME
  - 统一输入形式（将图像看作是一种“语言”），**文本 English、图像 Imaglish、图文对 Parallel Sentences**
- **预训练任务 Mask Data Modeling**
  - 输入形式统一之后，也就不需要 ITC、ITM、MLM 等其他目标函数，可以使用**统一的 mask“language” modeling 的方式进行训练**
- **模型 scaling up (将模型放大)**
  - 模型扩大到了 ViT-giant 的配置，参数量达到了 1.9B (vision/language 各一半)，提升多模态效果

1. 模型架构

> 从模型角度来说，Transformer 非常关键：
>
> - **Transformer 框架相比 CNN 的优势**：未来肯定是多模态的，一个模型做所有的 Modality，所有的 Task，肯定是一个大一统的框架。但是 CNN 不太适合做其他的 Modality，而 Transformer 就适合做很多的 Modality。从这一点上对比 Transformer 就胜出了。
> - VLP 常用框架：Dual Encoder、Encoder-Decoder、Fusion Encoder 三种框架，这个在前面介绍过。
>
> 不论是哪种方式，这些模型在遇到下游任务的时候，因为输入的形式可能会改变或者输出的形式有时候会改变，所以模型需要根据下游任务去做一些改进，因此不是真正意义上的 General Purpose Modeling。

所以，BEiT-v3 采用的是 VLMo 中使用的**MoME** (Mixture-of-Modality-Experts)，这里改了个名字叫 **Multiway Transformer。**

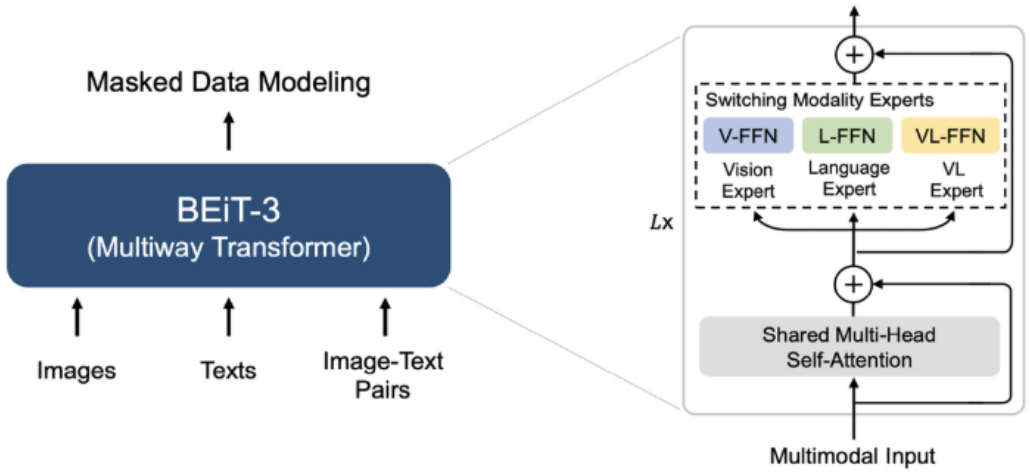


Figure 2: Overview of BEIT-3 pretraining. We perform masked data modeling on monomodal (i.e., images, and texts) and multimodal (i.e., image-text pairs) data with a shared Multiway Transformer as the backbone network.

BEiT-v3 预训练一个模型，通过模块化的搭积木，就可以灵活处理各种下游任务（每一个训练好的 Transformer Block、SA 层、FFN 都可以随意的拼装和组合）。

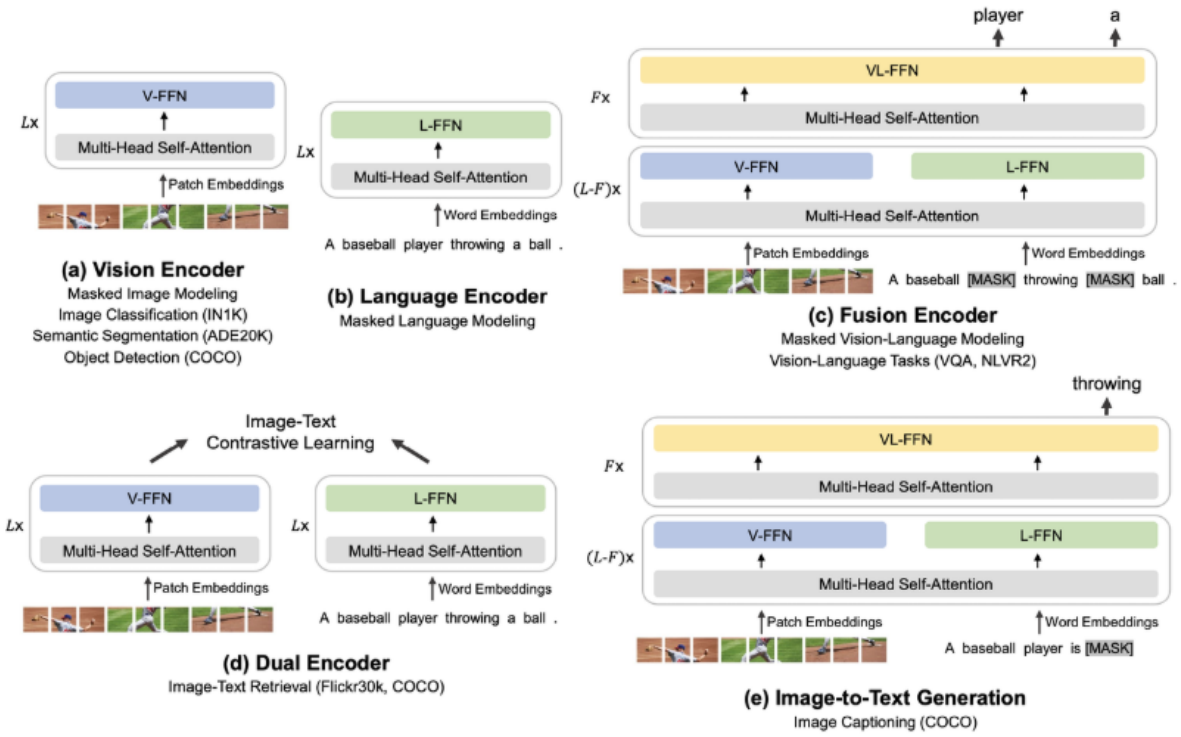


Figure 3: BEIT-3 can be transferred to various vision and vision-language downstream tasks. With a shared Multiway Transformer, we can reuse the model as (a)(b) vision or language encoders; (c) fusion encoders that jointly encode image-text pairs for deep interaction; (d) dual encoders that separately encode modalities for efficient retrieval; (e) sequence-to-sequence learning for image-to-text generation.

输入的数据根据模态的不同选择不同的 Expert，比如图片数据就使用 Vision FFN，文本数据就使用 Language FFN。模型前面的一些层是只有 Vision FFN 和 Language FFN，到了最后 3 层为了特征融合会再有 Vision-Language FFN。

- 图中 (a) 所示是 BEiT-v3 模型转换为视觉编码器，适配任务：图像分类，目标检测，语义分割；
- 图中 (b) 所示是 BEiT-v3 模型转换为文本编码器；

- 图中 (c) 所示是单塔结构，联合编码图像-文本对以进行深度交互的融合编码器，适配任务：多模态理解任务；
- 图中 (d) 所示是双塔结构，对每个模态进行单独编码以求高效的图文检索，适配任务：图文检索任务；
- 图中 (e) 所示是单塔结构，用于图像到文本生成任务，适配任务：多模态生成任务。

但是有人觉得 BEiT-v3 还不能算是 foundation model，因为它只是设计了比较精妙的 block，像搭积木一样做了排列组合。当时已经有人觉得应该用 language 作为 interface 将所有的任务统一起来，LLM 出现之后我们离这样的目标更近了一步。

2. 预训练任务

文本中以 BERT 为代表的MLM + 视觉中以 BEiT 为代表的MIM，这两种 Mask Data Modeling（MDM）预训练方式已经取得了成功。

BEiT-v3，将 MDM 扩展到多模态领域，进一步将所有多模态数据都看作是一种“语言”，以此统一预训练：

- **文本 English**
- **图像 Imaglish** （Image + English 造出来的词，Sequence of Token）
- **图文对 Parallel Sentences**（双语句对，句子 1 后面跟了个句子 2）

为什么要统一预训练方式?

- **MDM 已经广泛应用在**文本、图像、图文中，表明 MDM 作为一个目标函数已经可以很好地学习文本、图像和多模态特征。
- **用一个 loss 代替多个 loss 可以降低复杂度：**
  - 传统方法会用 ITM（Image-Text Matching）、ITC（Image-Text Contrastive）等多个损失函数，但这会带来：

    计算效率低：大模型和大数据集下计算成本高

    调参难度大：多个 loss 需要调整、平衡权重，有些 loss 可能互补，有些可能互斥

    人工调参难以 scale up：比如 ITM 需要 ITC 先找 hard negative，再做匹配，整个流程复杂
- **MDM 更有助于开展自监督学习**

MDM 的具体方法：

- 文本数据：由 SentencePiece tokenizer 进行 token 化
- 图像数据：由 BEiT-v2 的 tokenizer 进行 token 化，变成 Sequence of Token
- 具体 mask 方法：还是原来的 MLM、MIM 中的 mask 方法，从单模态文本中随机 mask 掉 15% 的文本，从图片-文本对中随机 mask 掉 50% 的文本，在 mask 图像时采用 block-wise 掩码策略 mask 掉 40%。
- 预训练目标：还是一样做完形填空，恢复掉被遮住的图像或文本。

3. 模型放大

Scaling up 是提高基础模型的泛化质量的有效方法，更有效的将模型转移到各种下游任务中。（因为只有用了更多的数据，有一个容量很大的模型，它才有可能用一个模型去解决所有的事情）

BEiT-v3 将模型大小扩展到 **Billions of Parameters**，数据集（**开源**）也扩展到非常大。

为什么 BEiT-3 可以轻松扩展模型规模?

因为它使用了**单一的 MDM 预训练目标**，从而避免了传统对比学习方法在批量大小（batch size）和计算资源上的挑战。

- 只使用 MDM，可以避免对比学习的 Batch Size 限制

对比学习的痛点：

- 需要**极大的 batch size** 才能保证模型学习到有意义的表示，因为它依赖**正负样本对比。**
- **显存和通信开销巨大**，使得在大模型上训练非常困难，需要大量工程优化。
- 如果 batch size 变小，对比学习的效果会显著下降，使得扩展模型变得更加困难。

BEiT-v3 的优势：

- 只使用 **MDM** 作为唯一的预训练任务，不依赖 batch 内样本的对比关系，因此 batch size 可以自由调整，而不会影响模型性能。
- **不再受 batch size 限制**，意味着可以更高效地训练更大的模型。

- 无 Batch 内依赖，适合梯度累积
  - 传统对比学习方法需要在 batch 内对不同样本进行计算，无法轻松使用梯度累积。
  - **BEiT-v3 由于只用 MDM，没有 batch 内部的交互依赖，天然适用于梯度累积**，可以高效训练超大规模模型。
- 可以直接借鉴 LLM 的 Scaling Up 经验
  - 由于 BEiT-3 采用 MDM，训练方式与 NLP 任务（如 BERT、GPT）类似，可以**直接复用语言模型的 Scaling Up 经验。**

4. 总结

BEiT-v3 其实从方法上来说就是之前 BEiT、BEiT-v2、VL-BEiT、VLMo 等一系列的工作的一个集合体，本身没有提出新的内容，主要就是把它做大做强，展示了一个 Unified Framework 能达到的性能。

到这里时，其实已经呈现了一个趋势，多模态模型的规模在不断扩大，训练用的数据规模也在扩大，虽然一定程度上对性能有利的，但是端到端训练的成本也会随之增加。

此时也就会有另外一种思考，有没有什么高效的对齐方法，直接利用已经预训练好的视觉、文本模型就能快速对齐，完成对模态任务。BLIP2 就进行了验证。