LLaVA-NeXT(2024, Microsoft Research)

博客：LLaVA-NeXT: Improved reasoning, OCR, and world knowledge
博客地址：https://llava-vl.github.io/blog/2024-01-30-llava-next/
项目地址：https://github.com/LLaVA-VL/LLaVA-NeXT

LLaVA-NeXT(LLaVA-1.6) 相比 LLaVA-1.5 有以下提升：

- 将输入图像分辨率提高 4 倍，使得它能够捕捉更多的视觉细节。它支持 3 种不同比例的分辨率，分别是 672x672、336x1344、1344x336
- 改变视觉指令微调数据的比例，实现更好的视觉推理和 OCR 能力，据说 34B 性能超过 Gemini-Pro
- 更好的视觉对话，适用于更多场景，涵盖不同应用。更丰富的世界知识和逻辑推理
- 使用 SGLang 实现高效部署和推理

1. 主要技术

1.1 Dynamic High-Resolution

同样使用 LLaVA-1.5 中的 AnyRes 策略处理高分辨率图像，并采用不同的切分配置 {2×2,1×{2,3,4},{2,3,4}×1} 来达到模型性能与训练（推理）成本之间的平衡。AnyRes 的具体步骤如下：

- 将高分辨率的图像分割成块，块的大小取决于视觉编码器能够处理的大小（例如 CLIP-ViT-L/14 可以处理的分辨率为 224*224）。视觉编码器单独处理每一块。
- 同时，将高分辨率的图像 resize 成视觉编码器能够处理的大小并使用视觉编码器进行编码。
- 将上面两步的结果拼接在一起作为视觉特征。

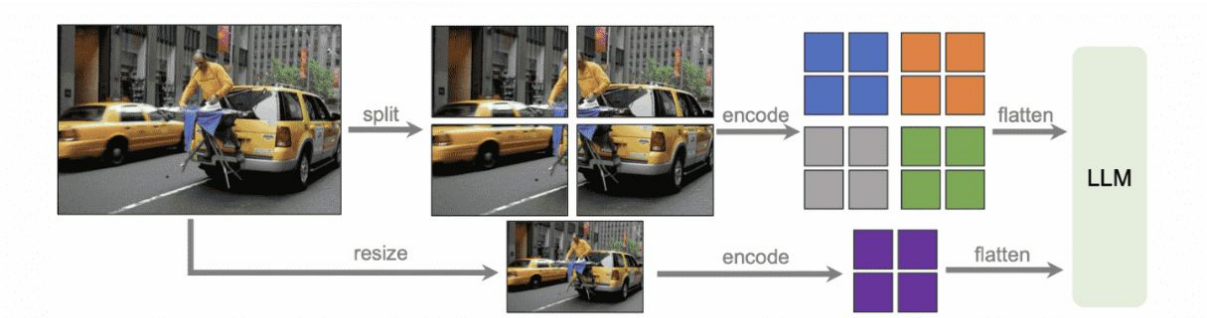


Illustration of dynamic high resolution scheme: a grid configuration of 2 × 2

1.2 Data Mixture

- **High-quality User Instruct Data**：多样性，高质量回复
- **Multimodal Document/Chart Data**：模仿Qwen-VL-7B-Chat增加了 ChartQA

1.3 Scaling LLM backbone

In addition to Vicuna-1.5 (7B and 13B), we consider more LLMs, including Mistral-7B and Nous-Hermes-2-Yi-34B.

2. Model Card

Name		LLaVA-NeXT-7B	LLaVA-NeXT-13B	LLaVA-NeXT-34B
Model Size	Total	**7.06B**	**13.35B**	**34.75B**
	Vision Encoder	303.5M	303.5M	303.5M
	Connector	21M	31.5M	58.7M
	LLM	6.74B	13B	34.39B
Resolution		336 x [(2,2), (1,2), (2,1), (1,3), (3,1), (1,4), (4,1)]		
Stage-1	**Training Data**	558K		
	Trainable Module	Connector		
Stage-2	**Training Data**	760K		
	Trainable Module	Full model		
Compute (#GPU x #Hours)		8x20	16x24	32x30
Training Data (#Samples)		1318K		

从 LLaVA --> LLaVA-1.5 --> LLaVA-NeXT，**输入分辨率依次增大，视觉编码器能力、连接器能力、LLM 基座能力更强，指令微调数据集包含更丰富、质量更高的数据集**

Reference

[1] LLaVA-NeXT: Improved reasoning, OCR, and world knowledge. https://llava-vl.github.io/blog/2024-01-30-llava-next/