SoViT

论文：《Getting ViT in Shape: Scaling Laws for Compute-Optimal Model Design》
论文链接：https://arxiv.org/pdf/2305.13035

1. 背景

在此前对 LLM 的研究中，Scaling Law 能够给出在给定的计算下，最佳模型的参数量。SoViT 在此基础上做了两件事：

- 将 Scaling Law 的视角引入到 ViT 上。
- 考虑内部维度形状（即 Width、Depth 和 MLP dim）随计算量（GFLOPs）关系。

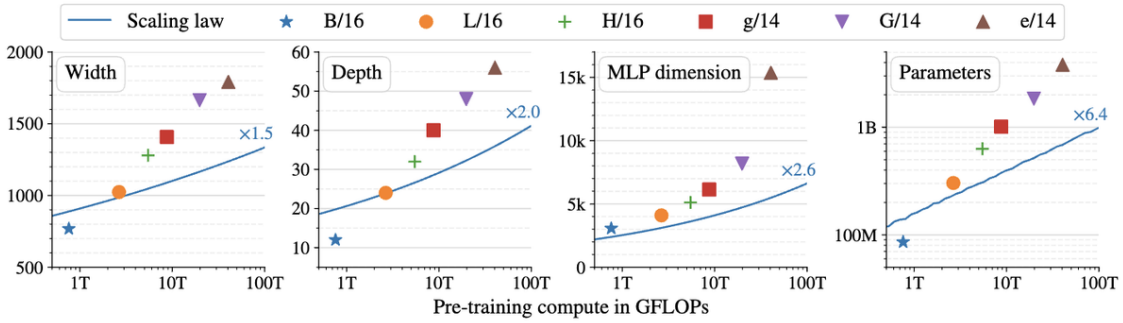


Figure 1: Predicted efficiency frontier (depth, width, MLP dimension, and parameter count) in SoViT. In large models, optimal shapes follow a similar trajectory in both image classification and multimodal tasks (see Section 4) although they can be different in small models (see Figure 3). We provide on the right (in blue) the amount of increase when compute goes from 1T to 100T GFLOPS.

从上图可以看到：

- 当计算量（GFLOPs）提高时，最优的模型对于 Width、Depth 和 MLP dim 有不同的缩放比率。
- 现在主流的 ViT 架构都是参数量冗余的（Shape 不是最优）

2. Scaling Strategy

2.1 问题描述

我们首先对问题作一个形式化描述。我们用一个元组 $x = (x_1, x_2, \ldots, x_D) \in \mathbb{N}^D$ 来表示一个神经网络的“形状”（即若干维度），例如宽度（width）、深度（depth）、MLP 的隐藏维度（MLP dim）等。我们用 t 表示训练计算量（例如 GFLOPs）。我们令 $f : \mathbb{N}^D \times \mathbb{R}_+ \to \mathbb{R}$ 表示一个关心的性能度量（performance metric），如下游任务的误差率（例如 ImageNet 10-shot 误差）。具体地，$f(x, t)$ 指：在一个给定的计算预算 t 下训练形状为 x 的网络，并测量得到的性能（通常是一个 Loss，值越低越好）。

我们的目标是：给定一个固定的计算预算 t，找到一个最优的形状 $x^\star$（该 $x^\star$ 将随 t 的变化而变化），使得：

$$f(x^\star, t) - \inf_{x \in \mathbb{N}^D} f(x, t) \leq \epsilon,$$

其中 ϵ 是一个很小的容忍度。由于实验测量、建模近似以及可试验的模型是有限的，我们无法期待 $\epsilon = 0$，因此需要允许一定的性能损失 ϵ。

2.2 单一形状维度的情况

在视觉 Transformer 中，仅仅改变网络的形状（例如宽度、深度、MLP 大小）就会显著影响它预训练后的下游表现。为了确定形状如何随计算量一起按比例扩展（scale up），让我们先考虑只有一个形状维度 x_k。类似于先前的一些工作，当考虑到计算量 t 时，人们往往需要跑大量实验来在不同 x_k 上找出优的 Pareto optimal frontier，并从中拟合出幂律关系，**然而这种做法代价昂贵。**

为此，SoViT 提出以下联合函数形式，用来同时考虑模型尺寸和训练计算量：

$$f_k(x_k, t) \sim \alpha_k x_k^{-a_k} + (\beta_k x_k^{b_k} + \xi_k) t^{-c} + \varepsilon_k,$$

其中 $\alpha_k, a_k, \beta_k, b_k, c, \xi_k, \varepsilon_k > 0$。$a_k$ 表示在“无计算限制”的情形下，当改变对应形状维度时所出现的“幂律指数”；c 则是表示数据规模幂律的指数；而 b_k 则反映了该形状维度对整体计算量（compute）所造成的影响。上式中，f_k 只聚焦维度 k，假设其他维度不会成为瓶颈（即它们足够大），并且假设数据量是充足的(不会过拟合)。**随后我们会借助实验数据来拟合其中的参数。**

直观而言，这个形式可从以下几点来理解：

1. **计算量无上限时**：假设训练可以无限长，则可得到熟悉的模型尺寸幂律关系 $f_k(x_k) \sim \alpha_k x_k^{-a_k} + \varepsilon_k$。这里的 ε_k 表示无法再降低的那部分损失。但是无限增大 x_k 无法使得 $f_k(x_k) \sim \varepsilon_k$ 因为联合函数的第二项会暴增。
2. **固定模型尺寸时**：公式只随 t（可视为相当于数据大小）变化，就会呈现 $\sim At^{-c} + B$ 的幂律关系；这与许多先前关于数据规模定律（data scaling laws）的观察一致。
3. **对固定计算量 t 而言**，$f_k(x_k, t)$ 关于 x_k 的曲线并非简单的单调，而是先下降后上升，呈现准凸（quasi-convex）形状（参考右侧 IsoFlop 曲线）。这意味着若把所有其他量都固定，盲目加大某个维度到某点后，实际可能会伤害最终性能。
4. **不互相矛盾**：若把这种分维度的函数形式通用化到多个维度，理论上也不会相互冲突，因为其可以写成一个可分解的加和式（见论文附录），且根据对数据流形维度的空间划分推断，c 这个指数在所有维度上都是一致的。
5. **在可用计算固定时的最优 x_k**：我们可以解析出最优值

   $$x_k^\star = \left(\frac{\alpha_k a_k t^c}{\beta_k b_k} \right)^{\frac{1}{b_k + a_k}} = O(t^{s_k}),$$

   其中 $s_k = \frac{c}{b_k + a_k}$.
   这告诉我们：在计算预算 t 按某个比例增大时，最优的某个维度 x_k 大致按 t^{s_k} 的幂律方式增长。因为 $a_k, b_k, c > 0$，所以 s_k 为正。
6. **在最优曲线（或最优前沿）上**，可将上式带回到 f_k 中，得到

   $$f_k(x_k, t) = F x_k^{-a_k} + G t^{-c} + \varepsilon_k,$$

   这与之前在语言模型中观察到的“在最优前沿时，损失是模型大小和计算量各自幂律之和”的结论一致。

2.3 多维度情况

SoViT 把这一思路推广到多个形状维度（如同时包含深度、宽度、MLP 大小等）。SoViT 用更少的实验就能定位到大致的最优形状。

2.3.1 Star Sweep（星形搜索）

如果我们想在 D 个不同的形状维度上做全面网格搜索，那么需要 $O(2^D)$ 个实验，这在实践中非常昂贵。为此，我们的做法是仅做“星形搜索”——即选定一个“中心”形状 $x^{(c)}$（各维都相对较大），随后“只动一个维度、保持其他不变”，并在这个维度上取一个按指数刻度排列的网格点来训练与测量，从而拟合式中的参数（特别是上文提到的 s_k）。例如在我们实验中，要拟合宽度 s_{width} 时，就把深度和 MLP 大小都固定在较大的中心值，分别训练宽度从小到较大的几种取值；对深度、MLP 也依此类推。

2.3.2 Grid Sweep（小模型网格搜索）

在上一步我们主要是估算每个维度各自的幂指数 s_k，而大模型中心点 $x^{(c)}$ 仅仅是为了确保它不会形成瓶颈。然而，当我们最终要获得一个“从小到大都最优”的完整形状扩展策略时，还需要知道在“小计算量”下的最优形状是什么。如果这个初始形状选得不佳，会在往后累加时造成偏离。

因此我们的第二步是：专门针对小模型、短训练（即计算量不大的情形）做一个更细致的网格搜索，从而找出在这部分计算量区间的 Pareto 最优形状 $x^{(0)}$。这样一来，这个小模型的“最优形状”就能作为后续向大规模延伸的起点，我们也就同时拿到式中可能涉及的系数，保证继续往大模型方向扩展时不会过早失真。

2.3.3 形状扩展策略

有了上面两个要点后，我们的总体做法如下：

- 首先，用“小模型网格搜索”来获得一个在计算量 $t^{(0)}$ 下的最优形状 $x^{(0)}$。
- 如果我们将计算量增加一个因子 τ（即由 $t^{(0)}$ 变为 $\tau \cdot t^{(0)}$），则根据前面结论，每个维度可大体按 $x_k \propto t^{s_k}$ 来扩张。
- 为简化，我们可以令所有维度在对数坐标上平均增长：比如说把 τ 分解为若干子增量，使各维度的乘法扩展在对数空间里相加即得 τ，从而每次的伸缩是固定倍数。但仍可考虑更灵活的做法，分配不同的增量权重 ω_k，如果有需求想要更快地扩张深度或是 MLP 等。

在 SoViT 的实验中采用了最简单且行之有效的方法，即让所有维度按照相同的对数步长增长。

3. 实验

3.1 Image Classification

ViT-g/14 参数量 1B、ViT-L/16 参数量 300M。相比之下 SoViT-400m/14 效果最佳。

Table 3: SoViT-400m/14 performs competitively with ViT-g/14 in 10-shot classification.

	INet [22]	CIFAR100 [46]	Pets [51]	Birds [74]	Caltech [25]	Cars [45]	Colorectal [40]	DTD [17]	UC [76]
ViT-L/16	81.5	82.2	97.0	97.1	89.9	93.8	79.4	72.0	96.3
SoViT-400m/14	**84.1**	86.7	**97.6**	**88.8**	**91.3**	93.6	**81.5**	72.5	97.7
ViT-g/14	84.0	**87.2**	97.4	88.5	89.3	**93.9**	78.9	**74.1**	**98.2**

3.2 Multitask Decoding

这些任务就是接上 Decoder 之后进行测评的，也最能表现 SoViT 在现在的 vlm 中的优越性：

Table 4: Summary of multitask decoding and zero-shot transfer results, see Sections 5.2 & 5.3.

Model	ImgNet	OCR-VQA [50]		GQA [37]		VQAv2 [28]		COCO Capt. [14]	
	Zero-shot	Acc [%]	Log-PPL	Acc [%]	Log-PPL	Acc [%]	Log-PPL	CIDEr	Log-PPL
ViT-L/16	79.9	48.3	17.9	55.3	24.9	66.4	20.9	120	28.7
SoViT-400M	82.2	**52.9**	**15.3**	56.0	23.9	67.7	20.9	**125**	**28.1**
ViT-g/14	**82.4**	52.5	15.9	**58.0**	**22.5**	**68.8**	**21.5**	**126**	**27.9**